

Análise Computacional de Problemas de Programação Não Linear em JuMP: Comparação entre IPOPT, MadNLP, NLOpt, Optim e UNO

Gabriel de Moraes Rezende^a

^a*Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal do Amazonas, Manaus, Amazonas, Brasil*

Abstract

Este artigo apresenta uma análise computacional de problemas de Programação Não Linear implementados em Julia por meio do JuMP. O estudo inicial compara os métodos de pontos interiores IPOPT e MadNLP a partir dos estados de término, tempos, iterações, função objetivo e medidas de inviabilidade. Um segundo experimento amplia a avaliação para os solvers IPOPT, MadNLP, NLOpt, Optim e UNO, utilizando 98 modelos distintos após o tratamento de repetições. No experimento ampliado, o MadNLP apresentou a maior taxa de sucesso, resolvendo 87 de 92 modelos (94,57%), seguido pelo IPOPT, com 81 de 92 (88,04%), NLOpt, com 79 de 95 (83,16%), e UNO, com 44 de 60 (73,33%). O Optim não iniciou a otimização nos 28 modelos avaliados devido a erros na interface para problemas restritos. Entre as execuções bem-sucedidas disponíveis, o IPOPT obteve o menor tempo em 78 modelos, o NLOpt em nove, o UNO em três e o MadNLP em dois. As medianas de tempo foram 0,471 s para IPOPT, 1,143 s para NLOpt, 2,007 s para UNO e 8,885 s para MadNLP. Apesar disso, nos 79 modelos resolvidos simultaneamente por IPOPT e MadNLP, o MadNLP utilizou mediana de 14 iterações, contra 27 do IPOPT. Os resultados demonstram que robustez, custo por iteração, sobrecarga de inicialização, tratamento de restrições e qualidade do ponto estacionário devem ser avaliados conjuntamente, especialmente em problemas não convexos.

Keywords: Programação não linear, JuMP, IPOPT, MadNLP, NLOpt, Optim, UNO, Benchmark computacional

1. Introdução

Problemas de Programação Não Linear aparecem em sistemas elétricos de potência, controle ótimo, engenharia mecânica, identificação de parâmetros, planejamento e diversas outras áreas. Em sua forma geral, um problema NLP pode ser escrito como

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeito a} \quad & g_i(x) = 0, \quad i \in \mathcal{E}, \\ & g_i(x) \leq 0, \quad i \in \mathcal{I}, \\ & x^L \leq x \leq x^U, \end{aligned} \tag{1}$$

em que $f(x)$ é a função objetivo, $g_i(x)$ representa as restrições e x^L e x^U são os limites das variáveis. Quando a função objetivo ou as restrições são não convexas, diferentes pontos iniciais e estratégias numéricas podem conduzir a soluções locais distintas.

Neste trabalho são comparados os solvers IPOPT e MadNLP. Ambos utilizam métodos de pontos interiores e resolvem, a cada iteração, sistemas associados às condições de Karush–Kuhn–Tucker. Entretanto, diferem em detalhes de implementação, regularização, solução dos sistemas lineares e integração com o ecossistema Julia. A comparação foi realizada com base em arquivos de resultados agregados e registros completos de iterações.

O objetivo é analisar não apenas qual solver foi mais rápido, mas também a robustez das execuções, a quantidade de iterações, a qualidade numérica das soluções e as limitações observadas na preparação dos modelos. Afinal, comparar solver olhando apenas uma coluna de tempo seria fácil demais, e aparentemente a computação científica decidiu que ninguém merece essa tranquilidade.

2. Metodologia

2.1. Ambiente experimental e dados analisados

Os modelos foram implementados em Julia com JuMP. Para cada solver foram gerados dois conjuntos de arquivos: um arquivo de resultados consolidados por execução e um arquivo contendo as informações de cada iteração. Os dados analisados foram:

- `resultado_ipopt_simple.csv`;

- `resultado_madnlp_simples.csv`;
- `iteracoes_ipopt_simples.csv`;
- `iteracoes_madnlp_simples.csv`.

Os arquivos incluem informações sobre estado de término, função objetivo, tempo, dimensões dos modelos, número de iterações e medidas de erro. Algumas instâncias aparecem mais de uma vez devido a reexecuções. Para evitar que repetições distorcessem a comparação, foi selecionada, para cada solver e modelo, a execução bem-sucedida com menor tempo registrado.

Foram considerados bem-sucedidos os estados `LOCALLY_SOLVED` e `ALMOST_LOCALLY_SOLVED`. Estados de limite de iterações, inviabilidade local, falha de inclusão e otimização não executada foram contabilizados separadamente.

2.2. Indicadores de desempenho

Os principais indicadores utilizados foram:

1. número de modelos resolvidos com sucesso;
2. tempo total de execução;
3. número de iterações;
4. valor final da função objetivo;
5. inviabilidade primal e dual;
6. complementaridade e erro global do NLP.

Para comparar os tempos nos modelos comuns, foi utilizada também a razão

$$\rho_i = \frac{t_i^{\text{MadNLP}}}{t_i^{\text{IPOPT}}}. \quad (2)$$

Como os tempos variam em várias ordens de grandeza, a tendência global foi resumida pela média geométrica:

$$\bar{\rho}_g = \exp \left(\frac{1}{N} \sum_{i=1}^N \ln \rho_i \right). \quad (3)$$

Valores de $\bar{\rho}_g > 1$ indicam vantagem do IPOPT, enquanto valores inferiores a um indicam vantagem do MadNLP.

3. Experimento 1: Comparação entre IPOPT e MadNLP

3.1. Robustez e estados de término

Após o tratamento das execuções duplicadas, o IPOPT apresentou 32 modelos resolvidos com sucesso. O MadNLP apresentou 29 modelos bem-sucedidos. Foram identificados 24 modelos comuns resolvidos pelos dois solvers.

A Figura 1 apresenta a distribuição dos principais estados de término. Os dados do MadNLP incluem falhas ocorridas antes da chamada efetiva do solver, especialmente erros de inclusão de arquivos, variáveis não definidas, arquivos auxiliares ausentes e erros de sintaxe em modelos convertidos.




Figura 1: Distribuição dos estados de término observados para IPOPT e MadNLP.

Essas falhas não devem ser atribuídas diretamente ao algoritmo numérico do MadNLP, pois ocorreram durante a preparação ou inclusão dos modelos. Entretanto, elas afetam a robustez do fluxo computacional completo e mostram que o processo de conversão e execução precisa ser padronizado antes de uma comparação estritamente algorítmica.

3.2. Comparação de tempos

A Figura 2 compara os tempos dos 24 modelos solucionados por ambos os solvers. Os eixos estão em escala logarítmica e a linha tracejada representa igualdade de desempenho. Pontos acima da diagonal indicam que o IPOPT foi mais rápido.




Figura 2: Comparação dos tempos de execução nos modelos resolvidos por ambos os solvers.

O IPOPT apresentou menor tempo em 23 dos 24 modelos comuns. O MadNLP foi mais rápido apenas no modelo `svanberg_jump`, com aproximadamente 31.26 s, contra 39.78 s do IPOPT. A razão geométrica MadNLP/IPOPT foi igual a 11,78. Portanto, considerando o conjunto avaliado, o MadNLP demandou aproximadamente 11,78 vezes o tempo do IPOPT em termos geométricos.

Parte dessa diferença é particularmente elevada nas instâncias QCQP convexas. Em modelos como `qcqp1000-1c`, `qcqp1500-1c` e `qcqp500-3c`, o IPOPT concluiu a execução em centésimos de segundo, enquanto os tempos totais do MadNLP ficaram próximos de nove segundos. Esse padrão sugere uma sobrecarga fixa relevante na medição do MadNLP, possivelmente associada à inicialização do processo, compilação ou preparação da interface. Por isso, os resultados representam o tempo do fluxo experimental adotado e não apenas o núcleo matemático do solver.

Tabela 1: Resumo dos resultados de tempo e iterações.

Indicador	IPOPT	MadNLP
Modelos resolvidos com sucesso	32	29
Modelos comuns resolvidos		24
Vitórias em tempo nos modelos comuns	23	1
Tempo mediano nas execuções bem-sucedidas (s)	7,78	19,13
Tempo médio nas execuções bem-sucedidas (s)	20,33	58,82
Iterações medianas	48	34
Iterações médias	166,44	165,79

3.3. Comparação do número de iterações

A Figura 3 compara o número de iterações nos modelos comuns. O MadNLP utilizou menos iterações em 11 modelos, o IPOPT utilizou menos em oito e houve empate em cinco.




Figura 3: Comparação do número de iterações nos modelos resolvidos por ambos os solvers.

Esse resultado evidencia que o número de iterações, isoladamente, não explica o tempo total. Por exemplo, o MadNLP reduziu o número de ite-

rações em modelos como `robot_1600` e `steering_12800`, mas permaneceu mais lento no tempo total. Isso pode decorrer de maior custo por iteração, diferenças na fatoração do sistema KKT, regularização, cálculo de derivadas ou sobrecarga de inicialização.

Em sentido oposto, nos modelos `clnlbeam` e `gasoil_3200`, o MadNLP executou consideravelmente mais iterações, o que também contribuiu para os maiores tempos. O modelo `clnlbeam` exigiu 554 iterações no IPOPT e 2053 no MadNLP. Para `gasoil_3200`, foram observadas 148 iterações no IPOPT e 796 no MadNLP.

3.4. Trajetória de convergência

A Figura 4 apresenta a inviabilidade primal ao longo das iterações do modelo `bearing_400_jump`. Nesse caso, os dois solvers convergiram em 17 iterações e produziram valores objetivos praticamente idênticos.




Figura 4: Evolução da inviabilidade primal no modelo `bearing_400_jump`.

A curva mostra que trajetórias diferentes podem conduzir ao mesmo ponto final. As decisões de passo, atualização do parâmetro de barreira e regularização alteram a evolução intermediária, mesmo quando os resultados finais são numericamente equivalentes.

3.5. Qualidade numérica das soluções

Nas execuções bem-sucedidas, a mediana do erro global do NLP foi aproximadamente $3,49 \times 10^{-8}$ para o IPOPT e $1,19 \times 10^{-8}$ para o MadNLP. A mediana da violação das restrições foi aproximadamente $3,26 \times 10^{-13}$ no IPOPT e $7,18 \times 10^{-10}$ no MadNLP.

Esses valores indicam que ambos os solvers produziram soluções numericamente consistentes na maior parte dos casos. A comparação direta dessas medidas deve ser feita com cautela, pois os critérios internos de término, escalonamento e cálculo do erro podem não ser rigorosamente idênticos.

3.6. Diferenças nos valores objetivos

Em várias instâncias convexas, os valores objetivos obtidos pelos dois solvers coincidiram até a precisão apresentada. Entretanto, algumas instâncias não convexas apresentaram diferenças relevantes. Por exemplo, no modelo `qcqp1500-1nc`, o IPOPT encontrou aproximadamente $-1116,045$, enquanto o MadNLP encontrou aproximadamente $-1179,101$.

Como ambos os estados indicam solução local, essa diferença não deve ser interpretada automaticamente como erro. Em problemas não convexas, os algoritmos podem convergir para pontos estacionários distintos. Nesse caso específico, considerando minimização e viabilidade comparável, o valor mais negativo do MadNLP representa uma solução local de melhor valor objetivo. Ainda assim, não há certificado de que essa solução seja globalmente ótima.

A Tabela 2 apresenta uma seleção de modelos representativos.

Tabela 2: Resultados selecionados para modelos resolvidos por ambos os solvers.

Modelo	t_{IP} (s)	t_{MA} (s)	it_{IP}	it_{MA}	f_{IP}	f_{MA}
bearing_400	3,786	13,910	17	17	-0,154293	-0,154293
robot_1600	5,405	16,882	104	34	9,140920	9,140962
steering_12800	17,658	25,144	76	18	0,554571	0,554571
svanberg	39,780	31,257	42	33	83623,821884	83623,822248
clnlbeam	86,611	234,816	554	2053	344,876131	344,876131
gasoil_3200	102,306	714,522	148	796	0,005237	0,005237
qcqp1500-1nc	0,136	10,647	93	271	-1116,045044	-1179,101145

4. Comparativo Consolidado do Experimento 1

Esta seção consolida todas as execuções registradas, incluindo modelos solucionados por ambos os solvers, modelos solucionados por apenas um deles

e casos encerrados por limite de iterações, falhas de preparação ou ausência de chamada efetiva ao otimizador. Ao todo, foram comparados 53 modelos distintos. Desses, 24 foram solucionados com sucesso pelos dois solvers. Considerando todos os modelos para os quais existiam tempos comparáveis, o IPOPT foi mais rápido em 28 casos, o MadNLP em 2, e 23 modelos não permitiram uma comparação direta de velocidade.

A Tabela 3 resume os principais indicadores do conjunto completo. A razão geométrica de tempo, calculada apenas sobre os modelos solucionados por ambos, permaneceu igual a 11.78. A razão mediana foi 3.61, mostrando que a vantagem do IPOPT não decorre somente de poucos valores extremos. A mediana da diferença absoluta entre os valores objetivos foi 7.379e-09. A maior diferença foi observada no modelo `qcqp1500-1nc_jump`, com valor absoluto de 6.306e+01; esse resultado deve ser interpretado em conjunto com o estado de término e com a possível não convexidade do problema.

Tabela 3: Resumo do comparativo consolidado de todos os modelos.

Indicador	Valor
Modelos distintos avaliados	53
Modelos solucionados por ambos	24
Casos com IPOPT mais rápido	28
Casos com MadNLP mais rápido	2
Casos sem comparação direta	23
Razão geométrica MadNLP/IPOPT nos casos comuns	11.78
Razão mediana MadNLP/IPOPT nos casos comuns	3.61
Mediana de $ \Delta f $ nos casos comuns	7.379e-09

A comparação consolidada também evidencia que o estado de término precisa ser analisado antes do tempo. Uma execução rápida com `ITERATION_LIMIT`, `OPTIMIZE_NOT_CALLED` ou erro de inclusão não é uma vitória numérica; é apenas o computador desistindo com eficiência admirável. Portanto, a coluna “solver mais rápido” da Tabela 4 deve ser interpretada juntamente com os estados de término.

Nos modelos solucionados pelos dois métodos, diferenças pequenas de objetivo combinadas com baixos erros primal e dual indicam convergência para soluções numericamente equivalentes. Diferenças elevadas podem ter três origens principais: convergência para pontos locais distintos, interrupção

prematura ou critérios internos de escalonamento e término diferentes. Por esse motivo, a tabela completa inclui status, tempos, razão de desempenho e iterações, permitindo distinguir desempenho computacional de qualidade de solução.

Tabela 4: Comparativo completo dos resultados de todos os modelos.

Modelo	S_{IP}	S_{MA}	t_{IP}	t_{MA}	t_{MA}/t_{IP}	it_{IP}	it_{MA}	Venc.
arki0003_jump	IL	IL	63.592	195.808	3.08	3000	3000	IP
arki0009_jump	LS	ONC	54.761	1777.346	32.46	555	–	IP
bearing_400_jump	LS	LS	3.786	13.910	3.67	17	17	IP
camshape_6400_jump	LS	LS	21.444	26.600	1.24	54	54	IP
clnlbeam_jump	LS	LS	86.611	234.816	2.71	554	2053	IP
cont5_1_1_jump	LS	LS	17.093	44.628	2.61	14	14	IP
cont5_2_1_1_jump	LS	LS	37.777	66.395	1.76	34	33	IP
cont5_2_2_1_jump	LS	LS	48.975	84.996	1.74	43	41	IP
cont5_2_3_1_jump	LS	LS	54.090	95.021	1.76	53	48	IP
cont5_2_4_1_jump	AUS	LS	–	75.848	–	–	9	–
corkscrew_jump	LS	LS	20.635	48.389	2.35	191	287	IP
dirichlet120_jump	AUS	AUS	–	–	–	–	–	–
dirichlet20_jump	AUS	AUS	–	–	–	–	–	–
dirichlet_jump	AUS	AUS	–	–	–	–	–	–
dtoc1nd_jump	LS	LS	15.124	33.906	2.24	8	8	IP
dtoc2_jump	AUS	ONC	–	849.725	–	–	–	–
elec_400_jump	LS	ONC	53.998	312.674	5.79	2461	–	IP
ex1_160_jump	AUS	ONC	–	1.176	–	–	–	–
ex1_160_jump (2)	LS	AUS	5.522	–	–	18	–	–
ex1_320_jump	AUS	ONC	–	0.956	–	–	–	–
ex1_320_jump (2)	LS	AUS	16.159	–	–	14	–	–
ex4_2_160_jump	AUS	LS	–	25.743	–	–	31	–
ex4_2_160_jump (2)	LS	AUS	5.695	–	–	17	–	–
ex4_2_320_jump	AUS	ONC	–	546.007	–	–	–	–
ex4_2_320_jump (2)	LS	AUS	22.094	–	–	16	–	–
ex8_2_2_jump	AUS	LS	–	16.217	–	–	67	–
ex8_2_2_jump (2)	LS	AUS	4.970	–	–	198	–	–
ex8_2_3_jump	AUS	LS	–	16.965	–	–	61	–
ex8_2_3_jump (2)	LS	AUS	9.330	–	–	211	–	–
gasoil_3200_jump	LS	LS	102.306	714.522	6.98	148	796	IP
henon120_jump	AUS	AUS	–	–	–	–	–	–
lane_emden120_jump	AUS	AUS	–	–	–	–	–	–
marine_1600_jump	AUS	AUS	–	–	–	–	–	–
nlq180_jump	AUS	AUS	–	–	–	–	–	–
nql180_jump	AUS	AUS	–	–	–	–	–	–

Continua na próxima página

Tabela 4 – continuação

Modelo	S_{IP}	S_{MA}	t_{IP}	t_{MA}	t_{MA}/t_{IP}	it_{IP}	it_{MA}	Venc.
optmass_jump	IL	LS	347.717	19.126	0.06	3000	38	MA
qcqp1000-1c_jump	LS	LS	0.023	9.028	399.44	9	5	IP
qcqp1000-1nc_jump	LS	LS	0.116	9.352	80.90	98	226	IP
qcqp1000-2c_jump	LS	LS	0.059	9.021	152.49	9	5	IP
qcqp1000-2nc_jump	LS	LS	0.266	9.552	35.94	80	246	IP
qcqp1500-1c_jump	LS	LS	0.028	9.072	323.47	9	5	IP
qcqp1500-1nc_jump	LS	LS	0.136	10.647	78.52	93	271	IP
qcqp500-3c_jump	LS	LS	0.036	9.036	251.83	9	5	IP
qcqp500-3nc_jump	LS	LS	0.165	9.210	55.69	75	158	IP
qcqp750-2c_jump	LS	LS	0.041	9.051	220.29	8	5	IP
qcqp750-2nc_jump	LS	LS	0.201	9.295	46.13	75	207	IP
robot_1600_jump	LS	LS	5.405	16.882	3.12	104	34	IP
robot_a_jump	AUS	AUS	–	–	–	–	–	–
robot_b_jump	LI	LI	5.840	16.492	2.82	723	324	IP
robot_c_jump	LI	LI	5.959	16.066	2.70	723	324	IP
rocket_12800_jump	ALS	LS	6.229	22.128	3.55	33	33	IP
steering_12800_jump	LS	LS	17.658	25.144	1.42	76	18	IP
svanberg_jump	LS	LS	39.780	31.257	0.79	42	33	MA

Legenda: LS = LOCALLY_SOLVED; ALS = ALMOST_LOCALLY_SOLVED; IL = ITERATION_LIMIT; ONC = OPTIMIZE_NOT_CALLED; LI = LOCALLY_INFEASIBLE; AUS = resultado ausente; IP = IPOPT; MA = MadNLP; E = empate; “–” = sem comparação.

A tabela detalhada mostra que a superioridade temporal do IPOPT é ampla no fluxo experimental utilizado, mas também expõe casos em que o MadNLP empregou menos iterações ou alcançou objetivos diferentes. Logo, a conclusão correta não é simplesmente que um solver “ganhou”, mas que o IPOPT apresentou menor custo total na configuração testada, enquanto o MadNLP demonstrou trajetórias iterativas competitivas em parte dos modelos e sensibilidade maior à preparação e à inicialização do ambiente.

5. Experimento 2: Avaliação Ampliada com Cinco Solvers

5.1. Objetivo e organização dos novos experimentos

O segundo conjunto de experimentos amplia a comparação para cinco interfaces de otimização disponíveis no ecossistema Julia: IPOPT, MadNLP, NLOpt, Optim e UNO. Os arquivos analisados foram `resultado_ipopt_simples_2.csv`, `resultado_madnlp_simples_2.csv`, `resultado_nlopt_simples_2.csv`, `resultado_optim_simples_2.csv` e `resultado_uno_simples_2.csv`, `iteracoes_ipopt_simples_2.csv` e `iteracoes_madnlp_simples_2.csv`.

Foram identificados 98 nomes de modelos distintos na união dos arquivos. Como IPOPT e UNO continham repetições, foi selecionada uma execução representativa por modelo, priorizando: (i) estados `LOCALLY_SOLVED` ou `ALMOST_LOCALLY_SOLVED`; (ii) execução efetivamente iniciada; e (iii) menor tempo `tempo_jump_s`. Esse procedimento evita que reexecuções idênticas sejam contabilizadas como novos problemas e fornece uma base comum para as estatísticas.

5.2. Configurações e parâmetros registrados

A Tabela 5 resume as configurações explicitamente registradas nos arquivos. Os valores refletem os parâmetros utilizados pelos scripts, não uma tentativa de tornar internamente idênticos algoritmos com naturezas diferentes.

Tabela 5: Configurações registradas no experimento ampliado.

Solver	Método ou preset	Limites e tolerâncias	Informações adicionais
IPOPT	Método de pontos interiores	tolerâncias internas do solver	iteraões, erros KKT e contagens de avaliações
MadNLP	Método de pontos interiores	tolerância de solução 10^{-7}	iteraões, NNZ do Jacobiano e da Hessiana
NLOpt	LD_SLSQP	<code>maxeval=3000; maxtime=1800 s; tol = 10^{-7}</code>	tolerância absoluta das restriões 10^{-7}
Optim	LBFGS	<code>max_iter=3000</code>	interface para problemas restritos não iniciou
UNO	<code>filtersqp</code>	<code>max_iter=3000; tol = 10^{-7}</code>	método SQP com filtro

Para IPOPT foram registrados: número de iterações, objetivo final do log, inviabilidade dual, violação das restrições, violação dos limites das variáveis, complementaridade, erro global do NLP, número de avaliações da

função objetivo, gradiente, restrições de igualdade e desigualdade, Jacobianos e Hessiana, além do tempo interno. Para MadNLP foram registrados os mesmos resíduos principais, o número de iterações, o tempo, os números de elementos não nulos do Jacobiano e da Hessiana e a função objetivo final. Os arquivos iterativos acrescentam objetivo, inviabilidade primal, inviabilidade dual, parâmetro de barreira, norma do passo, regularização, passos primal e dual, tipo de passo e número de buscas lineares.

5.3. Robustez e estados de término

A Figura 5 apresenta a cobertura dos solvers. O MadNLP obteve a maior taxa de sucesso, com 87 soluções em 92 modelos (94,57%). O IPOPT resolveu 81 de 92 (88,04%), o NLOpt 79 de 95 (83,16%) e o UNO 44 de 60 (73,33%). O Optim não produziu solução nos 28 modelos únicos avaliados.




Figura 5: Quantidade e proporção de modelos resolvidos no experimento ampliado.

A decomposição dos estados mostra 80 ocorrências `LOCALLY_SOLVED`, uma `ALMOST_LOCALLY_SOLVED` e 11 limites de iteração para IPOPT. O MadNLP apresentou 87 soluções locais, três estados `LOCALLY_INFEASIBLE` e dois limites de iteração. No NLOpt ocorreram 73 soluções locais, seis soluções quase locais, três limites de iteração, dois outros erros e 11 falhas de inclusão. No UNO foram observadas 44 soluções locais, seis limites de iteração, seis outros erros e quatro falhas de inclusão. Todas as execuções do Optim terminaram como `OPTIMIZE_NOT_CALLED`; os logs indicaram `StackOverflowError` na integração do método LBFGS com as restrições não lineares.

Esse resultado precisa ser interpretado corretamente: a taxa de sucesso mistura robustez algorítmica, compatibilidade da interface e preparação do modelo. Uma falha de inclusão não é evidência de incapacidade matemática do solver, enquanto uma inviabilidade local ou limite de iterações já ocorre durante o processo de otimização.

5.4. Comparação dos tempos computacionais

A Figura 6 apresenta a mediana e a média geométrica dos tempos bem-sucedidos em escala logarítmica. O IPOPT apresentou mediana de 0,471 s e média geométrica de 0,111 s. O NLOpt apresentou 1,143 s e 0,910 s, respectivamente. Para UNO, os valores foram 2,007 s e 1,671 s; para MadNLP, 8,885 s e 6,632 s.




Figura 6: Tempos agregados das execuções bem-sucedidas.

Considerando, para cada modelo, apenas os solvers que produziram solução aceitável, o IPOPT foi o mais rápido em 78 casos, o NLOpt em nove, o UNO em três e o MadNLP em dois. A Figura 7 resume essa contagem.




Figura 7: Número de vitórias em tempo entre as soluções bem-sucedidas disponíveis.

O perfil de desempenho de Dolan–Moré foi construído com os 89 modelos resolvidos por pelo menos dois dos quatro solvers efetivamente operacionais. Para cada modelo p e solver s , definiu-se

$$r_{p,s} = \frac{t_{p,s}}{\min_{\hat{s}} t_{p,\hat{s}}}, \quad (4)$$

e o perfil $\rho_s(\tau)$ corresponde à fração de modelos para os quais $r_{p,s} \leq \tau$. Como mostrado na Figura 8, a curva do IPOPT começa em nível mais alto, refletindo seu maior número de vitórias, e mantém maior cobertura para fatores de desempenho pequenos.




Figura 8: Perfil de desempenho dos quatro solvers que produziram soluções.

A diferença entre IPOPT e MadNLP é parcialmente explicada por uma sobrecarga quase fixa observada no tempo total do MadNLP em diversas instâncias pequenas. Portanto, os números representam o fluxo computacional completo medido pelos scripts e não apenas a complexidade assintótica do método numérico.

5.5. Iterações e custo por iteração

IPOPT e MadNLP foram os únicos solvers com arquivos detalhados de iterações. Eles resolveram simultaneamente 79 modelos no novo experimento. Nesse subconjunto, a mediana foi de 27 iterações para IPOPT e 14 para MadNLP. Assim, o MadNLP frequentemente percorreu menos passos principais, embora tenha apresentado maior tempo total.

Nos casos bem-sucedidos do IPOPT, a mediana foi de 27 iterações, 33 avaliações da função objetivo, 28 avaliações do gradiente, 33 avaliações das restrições de igualdade e 28 avaliações de seus Jacobianos. O maior número de iterações registrado entre as soluções aceitáveis foi 2992. Para MadNLP, a mediana foi 15 iterações, com máximos de 367 iterações, 5099 elementos não nulos no Jacobiano e 12596 elementos não nulos na Hessiana.

A conclusão é que o contador de iterações não pode ser usado isoladamente. Uma iteração pode envolver diferentes quantidades de avaliações,

fatorações, regularizações e buscas de linha. Em outras palavras, uma “iteração” não é uma moeda universal; cada solver cunha a sua e depois o pesquisador que lute para comparar.

5.6. Qualidade numérica e resíduos

Entre as soluções aceitáveis do IPOPT, as medianas da inviabilidade dual, violação das restrições, violação de limites, complementaridade e erro global do NLP foram, respectivamente, $6,66 \times 10^{-9}$, $1,71 \times 10^{-13}$, $9,31 \times 10^{-9}$, $1,00 \times 10^{-11}$ e $7,08 \times 10^{-9}$. Para MadNLP, as medianas da inviabilidade dual, violação das restrições, complementaridade e erro global foram $1,34 \times 10^{-11}$, $1,21 \times 10^{-11}$, $9,10 \times 10^{-9}$ e $9,14 \times 10^{-9}$.

Esses valores mostram que ambos os métodos de pontos interiores produziram resíduos baixos na maioria dos casos bem-sucedidos. Contudo, o máximo do erro global do IPOPT chegou a aproximadamente $9,97 \times 10^{-1}$ em uma solução ainda classificada como aceitável, evidenciando a necessidade de verificar individualmente os resíduos e não apenas o estado final retornado pela interface.

NLopt e UNO não forneceram nos arquivos o mesmo conjunto de métricas KKT. Para esses solvers, a qualidade foi avaliada principalmente pelo estado de término, viabilidade primal reportada e concordância da função objetivo.

5.7. Concordância da função objetivo

A Figura 9 apresenta a diferença relativa dos objetivos em relação ao IPOPT,

$$\delta_f = \frac{|f_s - f_{\text{IPOPT}}|}{1 + |f_{\text{IPOPT}}|}. \quad (5)$$

As medianas foram $4,54 \times 10^{-9}$ para MadNLP, $2,11 \times 10^{-8}$ para NLopt e $4,49 \times 10^{-9}$ para UNO. Portanto, na maior parte dos casos, os solvers convergiram para valores muito próximos. Entretanto, foram observados valores extremos elevados: o erro relativo máximo foi aproximadamente 750 para MadNLP, 443,67 para NLopt e 4,70 para UNO.




Figura 9: Diferença relativa dos objetivos em relação ao IPOPT.

Essas discrepâncias são compatíveis com três situações: convergência para mínimos locais distintos em problemas não convexos, diferenças no tratamento de viabilidade e término, ou execução em pontos iniciais efetivamente diferentes após transformações internas. Por isso, menor tempo só deve ser considerado uma vitória plena quando acompanhado de estado aceitável e objetivo comparável.

5.8. Síntese quantitativa do experimento ampliado

Tabela 6: Resumo quantitativo do segundo experimento.

Solver	Modelos	Sucessos	Taxa (%)	Mediana (s)	Média geométrica (s)
IPOPT	92	81	88,04	0,471	0,111
MadNLP	92	87	94,57	8,885	6,632
NLOpt	95	79	83,16	1,143	0,910
Optim	28	0	0,00	—	—
UNO	60	44	73,33	2,007	1,671

A Tabela 6 expõe um compromisso claro. O MadNLP foi o solver mais robusto em cobertura, mas o IPOPT foi amplamente superior em tempo no ambiente medido. NLOpt apresentou desempenho intermediário e obteve

nove vitórias, mostrando competitividade em parte das instâncias. UNO resolveu menos modelos, porém obteve três melhores tempos e objetivos geralmente próximos aos do IPOPT. O resultado do Optim revela uma limitação de compatibilidade da configuração adotada, não uma comparação válida de desempenho do método LBFGS.

5.9. Limitações do segundo experimento

As principais limitações são: diferenças de cobertura entre os arquivos; repetições não uniformes; ausência de múltiplas execuções para todos os solvers; tempos contendo compilação e inicialização; falta de resíduos KKT detalhados para NLOpt e UNO; falhas de inclusão; e incompatibilidade do Optim com parte da estrutura restrita. Além disso, os solvers empregam algoritmos diferentes, de modo que tolerâncias nominalmente iguais não garantem critérios de parada equivalentes.

Uma campanha futura deve executar todos os solvers no mesmo processo Julia após aquecimento, repetir cada modelo, armazenar tempo interno e externo separadamente, fixar pontos iniciais, registrar versões e resolvedores lineares e produzir intervalos de confiança. Só então dá para separar desempenho numérico de “o pacote resolveu compilar hoje”, que infelizmente continua sendo uma variável aleatória relevante.

6. Discussão

Os resultados favorecem claramente o IPOPT em tempo total para o conjunto analisado. Contudo, três fatores impedem uma conclusão universal. Primeiro, a medição do MadNLP parece conter uma parcela fixa próxima de nove segundos em várias instâncias pequenas, o que pode estar associado à compilação ou inicialização. Segundo, ocorreram erros de inclusão e preparação em parte dos modelos, reduzindo a cobertura do MadNLP sem que o solver propriamente dito fosse executado. Terceiro, os modelos não convexos podem convergir para soluções locais diferentes, tornando insuficiente uma comparação baseada apenas em tempo.

Para uma avaliação mais rigorosa, recomenda-se executar todos os modelos em um único processo Julia após uma etapa de aquecimento, separar tempo de compilação e tempo do solver, utilizar os mesmos pontos iniciais e tolerâncias, registrar o resolvedor linear empregado e repetir cada instância várias vezes. Também é recomendável empregar perfis de desempenho de

Dolan–Moré, que permitem comparar robustez e eficiência sem depender de médias sensíveis a valores extremos.

A análise das iterações mostra ainda que o MadNLP pode apresentar trajetórias competitivas em número de passos, mesmo quando perde em tempo. Isso sugere que otimizações na etapa de inicialização ou na configuração do sistema linear podem alterar substancialmente o resultado. Em outras palavras, o algoritmo não parece simplesmente “ruim”; o experimento é que inclui todo o pedágio da estrada, enquanto o IPOPT aparentemente já entrou na pista com o tanque cheio.

7. Conclusões

Este trabalho avaliou problemas de Programação Não Linear implementados em JuMP em dois estágios experimentais. O primeiro comparou IPOPT e MadNLP em um subconjunto inicial, demonstrando vantagem temporal do IPOPT e menor número de iterações do MadNLP em parte das instâncias.

O segundo experimento ampliou a avaliação para IPOPT, MadNLP, NLOpt, Optim e UNO. Após o tratamento de repetições, foram identificados 98 modelos distintos. O MadNLP apresentou a maior taxa de sucesso, resolvendo 87 de 92 modelos, enquanto o IPOPT resolveu 81 de 92, o NLOpt 79 de 95 e o UNO 44 de 60. O Optim não iniciou a otimização nos 28 modelos avaliados por incompatibilidade da interface restrita utilizada.

Em desempenho temporal, o IPOPT foi o solver mais rápido em 78 modelos, seguido por NLOpt em nove, UNO em três e MadNLP em dois. As medianas de tempo foram 0,471 s, 1,143 s, 2,007 s e 8,885 s para IPOPT, NLOpt, UNO e MadNLP, respectivamente. Nos 79 modelos resolvidos por IPOPT e MadNLP, a mediana de iterações foi 27 para IPOPT e 14 para MadNLP, confirmando que menos iterações não implica menor tempo.

Os resíduos registrados por IPOPT e MadNLP foram baixos na maioria das soluções aceitas. As diferenças medianas dos objetivos também foram pequenas para MadNLP, NLOpt e UNO quando comparados ao IPOPT. Entretanto, discrepâncias extremas em alguns modelos reforçam que problemas não convexos podem conduzir a pontos estacionários distintos e que `LOCALLY_SOLVED` não certifica ótimo global.

Conclui-se que o IPOPT apresentou o melhor compromisso entre velocidade e cobertura no ambiente testado, enquanto o MadNLP apresentou a maior robustez e menor contagem de iterações. NLOpt mostrou competitividade intermediária, e UNO obteve resultados promissores em uma cobertura

menor. O Optim exige correção da integração com problemas restritos antes de qualquer conclusão de desempenho.

Como trabalhos futuros, recomenda-se padronizar tolerâncias e pontos iniciais, eliminar falhas de inclusão, separar compilação e solução, executar múltiplas repetições após aquecimento, registrar versões e resolvedores lineares e aplicar perfis de desempenho e qualidade. Essas medidas permitirão uma comparação mais justa entre algoritmos, interfaces e custos de implementação.

Arquivos gerados

Os dados tratados e as figuras utilizadas no artigo estão organizados nas pastas `data/` e `figures/`. O arquivo `comparacao_modelos_comuns.csv` contém os 24 modelos resolvidos com sucesso por ambos os solvers. O arquivo `comparativo_geral_ipopt_madnlp.csv` reúne os modelos do primeiro experimento. Para o segundo experimento, o arquivo `comparativo_multisolver.csv` consolida status, tempos, objetivos, dimensões e solver mais rápido entre IPOPT, MadNLP, NLOpt, Optim e UNO.