

Análise Computacional de Problemas de Programação Não Linear em JuMP: Comparação entre IPOPT e MadNLP

Gabriel de Moraes Rezende^a

^a*Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal do Amazonas, Manaus, Amazonas, Brasil*

Abstract

Este artigo apresenta uma análise computacional de um conjunto de problemas de Programação Não Linear (NLP) implementados em Julia por meio do JuMP e resolvidos com os métodos de pontos interiores IPOPT e MadNLP. Os experimentos foram avaliados a partir dos estados de término, tempos de execução, número de iterações, valores da função objetivo e medidas de inviabilidade primal, dual, complementaridade e erro global do NLP. Após a remoção de execuções duplicadas e a seleção da execução bem-sucedida de menor tempo por modelo, o IPOPT solucionou 32 modelos, enquanto o MadNLP solucionou 29. Vinte e quatro modelos foram resolvidos com sucesso por ambos os solvers. Nesse subconjunto, o IPOPT apresentou menor tempo total em 23 casos, e o MadNLP em apenas um. A razão geométrica entre os tempos MadNLP/IPOPT foi aproximadamente 11,78, indicando vantagem global do IPOPT no ambiente experimental utilizado. Em contrapartida, o MadNLP empregou menos iterações em 11 dos 24 casos comuns, enquanto o IPOPT utilizou menos iterações em oito e houve empate em cinco. Os resultados mostram que menor número de iterações não implica necessariamente menor tempo computacional, pois o custo por iteração, a fatoração dos sistemas lineares, a inicialização e a interface com o modelo também influenciam o desempenho. Para instâncias não convexas, diferenças nos valores objetivos indicam convergência para pontos estacionários distintos, de modo que o estado `LOCALLY_SOLVED` não constitui certificado de otimalidade global.

Keywords: Programação não linear, Métodos de pontos interiores, JuMP, IPOPT, MadNLP, Benchmark computacional

1. Introdução

Problemas de Programação Não Linear aparecem em sistemas elétricos de potência, controle ótimo, engenharia mecânica, identificação de parâmetros, planejamento e diversas outras áreas. Em sua forma geral, um problema NLP pode ser escrito como

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeito a} \quad & g_i(x) = 0, \quad i \in \mathcal{E}, \\ & g_i(x) \leq 0, \quad i \in \mathcal{I}, \\ & x^L \leq x \leq x^U, \end{aligned} \tag{1}$$

em que $f(x)$ é a função objetivo, $g_i(x)$ representa as restrições e x^L e x^U são os limites das variáveis. Quando a função objetivo ou as restrições são não convexas, diferentes pontos iniciais e estratégias numéricas podem conduzir a soluções locais distintas.

Neste trabalho são comparados os solvers IPOPT e MadNLP. Ambos utilizam métodos de pontos interiores e resolvem, a cada iteração, sistemas associados às condições de Karush–Kuhn–Tucker. Entretanto, diferem em detalhes de implementação, regularização, solução dos sistemas lineares e integração com o ecossistema Julia. A comparação foi realizada com base em arquivos de resultados agregados e registros completos de iterações.

O objetivo é analisar não apenas qual solver foi mais rápido, mas também a robustez das execuções, a quantidade de iterações, a qualidade numérica das soluções e as limitações observadas na preparação dos modelos. Afinal, comparar solver olhando apenas uma coluna de tempo seria fácil demais, e aparentemente a computação científica decidiu que ninguém merece essa tranquilidade.

2. Metodologia

2.1. Ambiente experimental e dados analisados

Os modelos foram implementados em Julia com JuMP. Para cada solver foram gerados dois conjuntos de arquivos: um arquivo de resultados consolidados por execução e um arquivo contendo as informações de cada iteração. Os dados analisados foram:

- `resultado_ipopt_simple.csv`;

- `resultado_madnlp_simples.csv`;
- `iteracoes_ipopt_simples.csv`;
- `iteracoes_madnlp_simples.csv`.

Os arquivos incluem informações sobre estado de término, função objetivo, tempo, dimensões dos modelos, número de iterações e medidas de erro. Algumas instâncias aparecem mais de uma vez devido a reexecuções. Para evitar que repetições distorcessem a comparação, foi selecionada, para cada solver e modelo, a execução bem-sucedida com menor tempo registrado.

Foram considerados bem-sucedidos os estados `LOCALLY_SOLVED` e `ALMOST_LOCALLY_SOLVED`. Estados de limite de iterações, inviabilidade local, falha de inclusão e otimização não executada foram contabilizados separadamente.

2.2. Indicadores de desempenho

Os principais indicadores utilizados foram:

1. número de modelos resolvidos com sucesso;
2. tempo total de execução;
3. número de iterações;
4. valor final da função objetivo;
5. inviabilidade primal e dual;
6. complementaridade e erro global do NLP.

Para comparar os tempos nos modelos comuns, foi utilizada também a razão

$$\rho_i = \frac{t_i^{\text{MadNLP}}}{t_i^{\text{IPOPT}}}. \quad (2)$$

Como os tempos variam em várias ordens de grandeza, a tendência global foi resumida pela média geométrica:

$$\bar{\rho}_g = \exp \left(\frac{1}{N} \sum_{i=1}^N \ln \rho_i \right). \quad (3)$$

Valores de $\bar{\rho}_g > 1$ indicam vantagem do IPOPT, enquanto valores inferiores a um indicam vantagem do MadNLP.

3. Resultados Computacionais

3.1. Robustez e estados de término

Após o tratamento das execuções duplicadas, o IPOPT apresentou 32 modelos resolvidos com sucesso. O MadNLP apresentou 29 modelos bem-sucedidos. Foram identificados 24 modelos comuns resolvidos pelos dois solvers.

A Figura 1 apresenta a distribuição dos principais estados de término. Os dados do MadNLP incluem falhas ocorridas antes da chamada efetiva do solver, especialmente erros de inclusão de arquivos, variáveis não definidas, arquivos auxiliares ausentes e erros de sintaxe em modelos convertidos.




Figura 1: Distribuição dos estados de término observados para IPOPT e MadNLP.

Essas falhas não devem ser atribuídas diretamente ao algoritmo numérico do MadNLP, pois ocorreram durante a preparação ou inclusão dos modelos. Entretanto, elas afetam a robustez do fluxo computacional completo e mostram que o processo de conversão e execução precisa ser padronizado antes de uma comparação estritamente algorítmica.

3.2. Comparação de tempos

A Figura 2 compara os tempos dos 24 modelos solucionados por ambos os solvers. Os eixos estão em escala logarítmica e a linha tracejada representa igualdade de desempenho. Pontos acima da diagonal indicam que o IPOPT foi mais rápido.




Figura 2: Comparação dos tempos de execução nos modelos resolvidos por ambos os solvers.

O IPOPT apresentou menor tempo em 23 dos 24 modelos comuns. O MadNLP foi mais rápido apenas no modelo `svanberg_jump`, com aproximadamente 31.26 s, contra 39.78 s do IPOPT. A razão geométrica MadNLP/IPOPT foi igual a 11,78. Portanto, considerando o conjunto avaliado, o MadNLP demandou aproximadamente 11,78 vezes o tempo do IPOPT em termos geométricos.

Parte dessa diferença é particularmente elevada nas instâncias QCQP convexas. Em modelos como `qcqp1000-1c`, `qcqp1500-1c` e `qcqp500-3c`, o IPOPT concluiu a execução em centésimos de segundo, enquanto os tempos totais do MadNLP ficaram próximos de nove segundos. Esse padrão sugere uma sobrecarga fixa relevante na medição do MadNLP, possivelmente associada à inicialização do processo, compilação ou preparação da interface. Por isso, os resultados representam o tempo do fluxo experimental adotado e não apenas o núcleo matemático do solver.

Tabela 1: Resumo dos resultados de tempo e iterações.

Indicador	IPOPT	MadNLP
Modelos resolvidos com sucesso	32	29
Modelos comuns resolvidos		24
Vitórias em tempo nos modelos comuns	23	1
Tempo mediano nas execuções bem-sucedidas (s)	7,78	19,13
Tempo médio nas execuções bem-sucedidas (s)	20,33	58,82
Iterações medianas	48	34
Iterações médias	166,44	165,79

3.3. Comparação do número de iterações

A Figura 3 compara o número de iterações nos modelos comuns. O MadNLP utilizou menos iterações em 11 modelos, o IPOPT utilizou menos em oito e houve empate em cinco.




Figura 3: Comparação do número de iterações nos modelos resolvidos por ambos os solvers.

Esse resultado evidencia que o número de iterações, isoladamente, não explica o tempo total. Por exemplo, o MadNLP reduziu o número de ite-

rações em modelos como `robot_1600` e `steering_12800`, mas permaneceu mais lento no tempo total. Isso pode decorrer de maior custo por iteração, diferenças na fatoração do sistema KKT, regularização, cálculo de derivadas ou sobrecarga de inicialização.

Em sentido oposto, nos modelos `clnlbeam` e `gasoil_3200`, o MadNLP executou consideravelmente mais iterações, o que também contribuiu para os maiores tempos. O modelo `clnlbeam` exigiu 554 iterações no IPOPT e 2053 no MadNLP. Para `gasoil_3200`, foram observadas 148 iterações no IPOPT e 796 no MadNLP.

3.4. Trajetória de convergência

A Figura 4 apresenta a inviabilidade primal ao longo das iterações do modelo `bearing_400_jump`. Nesse caso, os dois solvers convergiram em 17 iterações e produziram valores objetivos praticamente idênticos.




Figura 4: Evolução da inviabilidade primal no modelo `bearing_400_jump`.

A curva mostra que trajetórias diferentes podem conduzir ao mesmo ponto final. As decisões de passo, atualização do parâmetro de barreira e regularização alteram a evolução intermediária, mesmo quando os resultados finais são numericamente equivalentes.

3.5. Qualidade numérica das soluções

Nas execuções bem-sucedidas, a mediana do erro global do NLP foi aproximadamente $3,49 \times 10^{-8}$ para o IPOPT e $1,19 \times 10^{-8}$ para o MadNLP. A mediana da violação das restrições foi aproximadamente $3,26 \times 10^{-13}$ no IPOPT e $7,18 \times 10^{-10}$ no MadNLP.

Esses valores indicam que ambos os solvers produziram soluções numericamente consistentes na maior parte dos casos. A comparação direta dessas medidas deve ser feita com cautela, pois os critérios internos de término, escalonamento e cálculo do erro podem não ser rigorosamente idênticos.

3.6. Diferenças nos valores objetivos

Em várias instâncias convexas, os valores objetivos obtidos pelos dois solvers coincidiram até a precisão apresentada. Entretanto, algumas instâncias não convexas apresentaram diferenças relevantes. Por exemplo, no modelo `qcqp1500-1nc`, o IPOPT encontrou aproximadamente $-1116,045$, enquanto o MadNLP encontrou aproximadamente $-1179,101$.

Como ambos os estados indicam solução local, essa diferença não deve ser interpretada automaticamente como erro. Em problemas não convexas, os algoritmos podem convergir para pontos estacionários distintos. Nesse caso específico, considerando minimização e viabilidade comparável, o valor mais negativo do MadNLP representa uma solução local de melhor valor objetivo. Ainda assim, não há certificado de que essa solução seja globalmente ótima.

A Tabela 2 apresenta uma seleção de modelos representativos.

Tabela 2: Resultados selecionados para modelos resolvidos por ambos os solvers.

Modelo	t_{IP} (s)	t_{MA} (s)	it_{IP}	it_{MA}	f_{IP}	f_{MA}
bearing_400	3,786	13,910	17	17	-0,154293	-0,154293
robot_1600	5,405	16,882	104	34	9,140920	9,140962
steering_12800	17,658	25,144	76	18	0,554571	0,554571
svanberg	39,780	31,257	42	33	83623,821884	83623,822248
clnlbeam	86,611	234,816	554	2053	344,876131	344,876131
gasoil_3200	102,306	714,522	148	796	0,005237	0,005237
qcqp1500-1nc	0,136	10,647	93	271	-1116,045044	-1179,101145

4. Comparativo Geral de Todos os Modelos

Esta seção consolida todas as execuções registradas, incluindo modelos solucionados por ambos os solvers, modelos solucionados por apenas um deles

e casos encerrados por limite de iterações, falhas de preparação ou ausência de chamada efetiva ao otimizador. Ao todo, foram comparados 53 modelos distintos. Desses, 24 foram solucionados com sucesso pelos dois solvers. Considerando todos os modelos para os quais existiam tempos comparáveis, o IPOPT foi mais rápido em 28 casos, o MadNLP em 2, e 23 modelos não permitiram uma comparação direta de velocidade.

A Tabela 3 resume os principais indicadores do conjunto completo. A razão geométrica de tempo, calculada apenas sobre os modelos solucionados por ambos, permaneceu igual a 11.78. A razão mediana foi 3.61, mostrando que a vantagem do IPOPT não decorre somente de poucos valores extremos. A mediana da diferença absoluta entre os valores objetivos foi 7.379e-09. A maior diferença foi observada no modelo `qcqp1500-1nc_jump`, com valor absoluto de 6.306e+01; esse resultado deve ser interpretado em conjunto com o estado de término e com a possível não convexidade do problema.

Tabela 3: Resumo do comparativo consolidado de todos os modelos.

Indicador	Valor
Modelos distintos avaliados	53
Modelos solucionados por ambos	24
Casos com IPOPT mais rápido	28
Casos com MadNLP mais rápido	2
Casos sem comparação direta	23
Razão geométrica MadNLP/IPOPT nos casos comuns	11.78
Razão mediana MadNLP/IPOPT nos casos comuns	3.61
Mediana de $ \Delta f $ nos casos comuns	7.379e-09

A comparação consolidada também evidencia que o estado de término precisa ser analisado antes do tempo. Uma execução rápida com `ITERATION_LIMIT`, `OPTIMIZE_NOT_CALLED` ou erro de inclusão não é uma vitória numérica; é apenas o computador desistindo com eficiência admirável. Portanto, a coluna “solver mais rápido” da Tabela 4 deve ser interpretada juntamente com os estados de término.

Nos modelos solucionados pelos dois métodos, diferenças pequenas de objetivo combinadas com baixos erros primal e dual indicam convergência para soluções numericamente equivalentes. Diferenças elevadas podem ter três origens principais: convergência para pontos locais distintos, interrupção

prematura ou critérios internos de escalonamento e término diferentes. Por esse motivo, a tabela completa inclui status, tempos, razão de desempenho e iterações, permitindo distinguir desempenho computacional de qualidade de solução.

Tabela 4: Comparativo completo dos resultados de todos os modelos.

Modelo	S_{IP}	S_{MA}	t_{IP}	t_{MA}	t_{MA}/t_{IP}	it_{IP}	it_{MA}	Venc.
arki0003_jump	IL	IL	63.592	195.808	3.08	3000	3000	IP
arki0009_jump	LS	ONC	54.761	1777.346	32.46	555	–	IP
bearing_400_jump	LS	LS	3.786	13.910	3.67	17	17	IP
camshape_6400_jump	LS	LS	21.444	26.600	1.24	54	54	IP
clnlbeam_jump	LS	LS	86.611	234.816	2.71	554	2053	IP
cont5_1_1_jump	LS	LS	17.093	44.628	2.61	14	14	IP
cont5_2_1_1_jump	LS	LS	37.777	66.395	1.76	34	33	IP
cont5_2_2_1_jump	LS	LS	48.975	84.996	1.74	43	41	IP
cont5_2_3_1_jump	LS	LS	54.090	95.021	1.76	53	48	IP
cont5_2_4_1_jump	AUS	LS	–	75.848	–	–	9	–
corkscrew_jump	LS	LS	20.635	48.389	2.35	191	287	IP
dirichlet120_jump	AUS	AUS	–	–	–	–	–	–
dirichlet20_jump	AUS	AUS	–	–	–	–	–	–
dirichlet_jump	AUS	AUS	–	–	–	–	–	–
dtoc1nd_jump	LS	LS	15.124	33.906	2.24	8	8	IP
dtoc2_jump	AUS	ONC	–	849.725	–	–	–	–
elec_400_jump	LS	ONC	53.998	312.674	5.79	2461	–	IP
ex1_160_jump	AUS	ONC	–	1.176	–	–	–	–
ex1_160_jump (2)	LS	AUS	5.522	–	–	18	–	–
ex1_320_jump	AUS	ONC	–	0.956	–	–	–	–
ex1_320_jump (2)	LS	AUS	16.159	–	–	14	–	–
ex4_2_160_jump	AUS	LS	–	25.743	–	–	31	–
ex4_2_160_jump (2)	LS	AUS	5.695	–	–	17	–	–
ex4_2_320_jump	AUS	ONC	–	546.007	–	–	–	–
ex4_2_320_jump (2)	LS	AUS	22.094	–	–	16	–	–
ex8_2_2_jump	AUS	LS	–	16.217	–	–	67	–
ex8_2_2_jump (2)	LS	AUS	4.970	–	–	198	–	–
ex8_2_3_jump	AUS	LS	–	16.965	–	–	61	–
ex8_2_3_jump (2)	LS	AUS	9.330	–	–	211	–	–
gasoil_3200_jump	LS	LS	102.306	714.522	6.98	148	796	IP
henon120_jump	AUS	AUS	–	–	–	–	–	–
lane_emden120_jump	AUS	AUS	–	–	–	–	–	–
marine_1600_jump	AUS	AUS	–	–	–	–	–	–
nlq180_jump	AUS	AUS	–	–	–	–	–	–
nql180_jump	AUS	AUS	–	–	–	–	–	–

Continua na próxima página

Tabela 4 – continuação

Modelo	S_{IP}	S_{MA}	t_{IP}	t_{MA}	t_{MA}/t_{IP}	it_{IP}	it_{MA}	Venc.
optmass_jump	IL	LS	347.717	19.126	0.06	3000	38	MA
qcqp1000-1c_jump	LS	LS	0.023	9.028	399.44	9	5	IP
qcqp1000-1nc_jump	LS	LS	0.116	9.352	80.90	98	226	IP
qcqp1000-2c_jump	LS	LS	0.059	9.021	152.49	9	5	IP
qcqp1000-2nc_jump	LS	LS	0.266	9.552	35.94	80	246	IP
qcqp1500-1c_jump	LS	LS	0.028	9.072	323.47	9	5	IP
qcqp1500-1nc_jump	LS	LS	0.136	10.647	78.52	93	271	IP
qcqp500-3c_jump	LS	LS	0.036	9.036	251.83	9	5	IP
qcqp500-3nc_jump	LS	LS	0.165	9.210	55.69	75	158	IP
qcqp750-2c_jump	LS	LS	0.041	9.051	220.29	8	5	IP
qcqp750-2nc_jump	LS	LS	0.201	9.295	46.13	75	207	IP
robot_1600_jump	LS	LS	5.405	16.882	3.12	104	34	IP
robot_a_jump	AUS	AUS	–	–	–	–	–	–
robot_b_jump	LI	LI	5.840	16.492	2.82	723	324	IP
robot_c_jump	LI	LI	5.959	16.066	2.70	723	324	IP
rocket_12800_jump	ALS	LS	6.229	22.128	3.55	33	33	IP
steering_12800_jump	LS	LS	17.658	25.144	1.42	76	18	IP
svanberg_jump	LS	LS	39.780	31.257	0.79	42	33	MA

Legenda: LS = LOCALLY_SOLVED; ALS = ALMOST_LOCALLY_SOLVED; IL = ITERATION_LIMIT; ONC = OPTIMIZE_NOT_CALLED; LI = LOCALLY_INFEASIBLE; AUS = resultado ausente; IP = IPOPT; MA = MadNLP; E = empate; “–” = sem comparação.

A tabela detalhada mostra que a superioridade temporal do IPOPT é ampla no fluxo experimental utilizado, mas também expõe casos em que o MadNLP empregou menos iterações ou alcançou objetivos diferentes. Logo, a conclusão correta não é simplesmente que um solver “ganhou”, mas que o IPOPT apresentou menor custo total na configuração testada, enquanto o MadNLP demonstrou trajetórias iterativas competitivas em parte dos modelos e sensibilidade maior à preparação e à inicialização do ambiente.

5. Discussão

Os resultados favorecem claramente o IPOPT em tempo total para o conjunto analisado. Contudo, três fatores impedem uma conclusão universal. Primeiro, a medição do MadNLP parece conter uma parcela fixa próxima de nove segundos em várias instâncias pequenas, o que pode estar associado à compilação ou inicialização. Segundo, ocorreram erros de inclusão e preparação em parte dos modelos, reduzindo a cobertura do MadNLP sem que o solver propriamente dito fosse executado. Terceiro, os modelos não convexos podem convergir para soluções locais diferentes, tornando insuficiente uma comparação baseada apenas em tempo.

Para uma avaliação mais rigorosa, recomenda-se executar todos os modelos em um único processo Julia após uma etapa de aquecimento, separar tempo de compilação e tempo do solver, utilizar os mesmos pontos iniciais e tolerâncias, registrar o resolvidor linear empregado e repetir cada instância várias vezes. Também é recomendável empregar perfis de desempenho de Dolan–Moré, que permitem comparar robustez e eficiência sem depender de médias sensíveis a valores extremos.

A análise das iterações mostra ainda que o MadNLP pode apresentar trajetórias competitivas em número de passos, mesmo quando perde em tempo. Isso sugere que otimizações na etapa de inicialização ou na configuração do sistema linear podem alterar substancialmente o resultado. Em outras palavras, o algoritmo não parece simplesmente “ruim”; o experimento é que inclui todo o pedágio da estrada, enquanto o IPOPT aparentemente já entrou na pista com o tanque cheio.

6. Conclusões

Este trabalho comparou o desempenho computacional dos solvers IPOPT e MadNLP em modelos de Programação Não Linear implementados em

JuMP. Após o tratamento das duplicidades, o IPOPT solucionou 32 modelos e o MadNLP solucionou 29. Vinte e quatro modelos foram resolvidos por ambos.

No subconjunto comum, o IPOPT foi mais rápido em 23 casos, enquanto o MadNLP foi mais rápido apenas no modelo `svanberg`. A razão geométrica dos tempos MadNLP/IPOPT foi aproximadamente 11,78. Em relação ao número de iterações, o MadNLP apresentou vantagem em 11 casos, o IPOPT em oito e houve cinco empates, demonstrando que a quantidade de iterações não determina sozinha o custo computacional.

Ambos os solvers produziram baixos níveis de inviabilidade e erro nos casos bem-sucedidos. Nas instâncias não convexas, foram observados valores objetivos distintos, coerentes com a possibilidade de convergência para diferentes soluções locais. Assim, estados de solução local não devem ser confundidos com certificados de otimalidade global.

Como trabalhos futuros, recomenda-se eliminar os erros de inclusão, separar tempos de compilação e solução, padronizar tolerâncias e pontos iniciais, realizar múltiplas repetições e construir perfis de desempenho. Essas medidas permitirão distinguir com maior precisão o desempenho do algoritmo numérico da sobrecarga do ambiente de execução.

Arquivos gerados

Os dados tratados e as figuras utilizadas no artigo estão organizados nas pastas `data/` e `figures/`. O arquivo `comparacao_modelos_comuns.csv` contém os 24 modelos resolvidos com sucesso por ambos os solvers. O arquivo `comparativo_geral_ipopt_madnlp.csv` reúne os 53 modelos do comparativo consolidado apresentado na Seção 4.