

OTIMIZAÇÃO

**Trabalho 01 - Resolução
computacional (Benchmark de
NLP e benchmark COCONUT)**

Hercules André

July 2026

Sumário

1	Análise de Desempenho do Solver IPOPT - AMPL-NLP Benchmark	4
1.1	Resumo Executivo e Taxa de Sucesso	4
1.2	Análise Estatística dos Tempos de Execução	4
1.3	Análise do Comportamento Iterativo do Método	5
1.4	Discussão Técnica do Desempenho	6
1.5	Conclusão	6
2	Análise de Desempenho do Solver Optim - AMPL-NLP Benchmark	7
2.1	Resumo Executivo e Taxa de Sucesso	7
2.2	Análise do Processo Iterativo e Convergência	7
2.3	Análise dos Tempos Computacionais	8
2.4	Resumo Estatístico dos Resultados	8
2.5	Discussão Técnica e Recomendações	9
2.6	Conclusão	9
3	Análise de Desempenho do UNOSolver - AMPL-NLP Benchmark	9
3.1	Resumo Executivo e Taxa de Sucesso	9
3.2	Análise do Comportamento Computacional	10
3.3	Desempenho nas Instâncias Resolvidas	10
3.4	Análise das Instâncias Limitadas pelo Tempo	11
3.5	Resumo Estatístico dos Resultados	11
3.6	Conclusão da Avaliação do UNOSolver	12
4	Análise de Desempenho do Solver MadNLP - AMPL-NLP Benchmark	12
4.1	Resumo Executivo e Taxa de Sucesso	12
4.2	Análise do Comportamento das Iterações	13
4.3	Avaliação do Desempenho Computacional	13
4.4	Precisão das Soluções Obtidas	14
4.5	Resumo dos Resultados	15
4.6	Considerações Finais	15
5	Análise de Desempenho do Solver IPOPT no Benchmark COCONUT	16
5.1	Resumo Executivo e Taxa de Sucesso	16
5.2	Análise do Comportamento Computacional	16
5.3	Comportamento do IPOPT Frente às Características do Benchmark COCONUT	17
5.4	Resumo Estatístico dos Resultados	17
5.5	Discussão Técnica e Recomendações	18
5.6	Conclusão	18

6	Análise de Desempenho do Solver MadNLP no Benchmark CO- CONUT	19
6.1	Resumo Executivo e Taxa de Sucesso	19
6.2	Análise do Comportamento Computacional	19
6.2.1	Relação entre Tempo Computacional e Iterações	19
6.3	Precisão Numérica das Soluções Obtidas	20
6.4	Resultados Consolidados	20
6.5	Discussão Técnica e Comparação de Robustez	21
6.6	Conclusões e Trabalhos Futuros	21

1 Análise de Desempenho do Solver IPOPT - AMPL-NLP Benchmark

1.1 Resumo Executivo e Taxa de Sucesso

O solver *Interior Point OPTimizer* (IPOPT) foi avaliado utilizando um conjunto de 44 problemas de Programação Não Linear (NLP), pertencentes ao benchmark clássico de Mittelmann, amplamente utilizado na literatura para avaliação de desempenho de solvers de otimização contínua.

Os resultados experimentais demonstraram elevada robustez numérica do algoritmo, com todas as instâncias apresentando convergência bem-sucedida. A taxa de sucesso obtida foi de:

$$TaxadeConvergência = \frac{44}{44} \times 100 = 100\% \quad (1)$$

Todas as execuções retornaram o estado *LOCALLY_SOLVED*, indicando que o IPOPT encontrou uma solução estacionária que satisfaz as condições necessárias de otimalidade de Karush-Kuhn-Tucker (KKT), considerando as tolerâncias numéricas definidas pelo ambiente computacional.

É importante destacar que, por se tratar de um método de pontos interiores para otimização contínua local, o IPOPT não fornece certificados de otimalidade global para problemas não convexos. Dessa forma, métricas tradicionais como *dual gap*, utilizadas em métodos baseados em relaxações convexas ou algoritmos Branch-and-Bound, não são aplicáveis diretamente neste contexto.

1.2 Análise Estatística dos Tempos de Execução

O desempenho computacional foi analisado considerando duas métricas principais: o tempo total de execução do processo (*total_time*) e o tempo efetivamente consumido pelo núcleo de otimização (*solver_time*). A Tabela 1 apresenta os principais indicadores estatísticos.

Tabela 1: Estatísticas dos tempos de execução do IPOPT para 44 instâncias NLP.

Métrica	Tempo Total (s)	Tempo Solver (s)
Mínimo	0,088	0,082
Máximo	28,411	17,448
Média	1,029	0,724
Mediana	0,575	0,505

Os resultados evidenciam que o IPOPT apresentou desempenho computacional altamente eficiente para a maioria das instâncias avaliadas. O tempo médio de solução permaneceu inferior a um segundo, enquanto a mediana apresentou valor ainda menor, indicando que a distribuição dos tempos é fortemente

assimétrica devido à presença de poucas instâncias computacionalmente mais exigentes.

A diferença observada entre média e mediana demonstra a influência de problemas *outliers*, especialmente a instância *camshape100*, responsável pelo maior custo computacional do conjunto analisado. Essa instância apresentou:

- Tempo total de execução: 28,411 segundos;
- Tempo interno do solver: 17,448 segundos.

Esse comportamento sugere que a dificuldade computacional não está associada ao processo de inicialização ou leitura do modelo, mas principalmente ao processo interno de resolução do sistema linear associado às condições KKT. Durante cada iteração do IPOPT, é necessário resolver um sistema aumentado derivado da linearização das restrições e da aproximação da Hessiana da função Lagrangiana. Assim, problemas com estruturas geométricas específicas ou matrizes mal condicionadas podem provocar aumento significativo no custo das fatorações lineares.

1.3 Análise do Comportamento Iterativo do Método

Apesar do desempenho computacional satisfatório, foi identificado um comportamento atípico na métrica relacionada ao número de iterações. Todas as 44 instâncias reportaram:

$$iterations = 1 \tag{2}$$

Esse comportamento não é esperado para problemas NLP pertencentes ao benchmark de Mittelmann, considerando que diversas instâncias possuem características fortemente não lineares e normalmente demandam múltiplas iterações do método de barreira logarítmica utilizado pelo IPOPT.

No funcionamento convencional do algoritmo, cada iteração do método de pontos interiores envolve:

1. Atualização das variáveis primais;
2. Atualização das variáveis duais associadas às restrições;
3. Redução progressiva do parâmetro de barreira;
4. Resolução do sistema linear baseado na aproximação das condições KKT;
5. Verificação dos resíduos primal, dual e complementar.

Portanto, a ocorrência de apenas uma iteração para todas as instâncias sugere uma condição experimental específica. As hipóteses mais prováveis são:

- **Inicialização próxima da solução ótima:** utilização de *warm-start* ou pontos iniciais previamente ajustados, fazendo com que os resíduos KKT estejam próximos das tolerâncias de parada;

- **Configuração específica do ambiente de execução:** o modelo pode estar sendo carregado com valores iniciais que reduzem significativamente o esforço iterativo;
- **Problema no registro da métrica:** a variável responsável pelo armazenamento do número de iterações pode não estar refletindo corretamente o comportamento interno do IPOPT durante a exportação dos resultados.

Dessa forma, embora os resultados indiquem excelente desempenho computacional, a métrica de iterações deve ser interpretada com cautela, pois o comportamento observado não representa o padrão normalmente encontrado em benchmarks NLP de alta complexidade.

1.4 Discussão Técnica do Desempenho

O desempenho apresentado pelo IPOPT confirma a eficiência dos métodos de pontos interiores para problemas de otimização contínua de médio porte. A combinação entre uma estratégia de barreira logarítmica, aproximação eficiente da Hessiana da função Lagrangiana e técnicas robustas de fatoração linear permite que o solver obtenha soluções de alta qualidade em tempos reduzidos.

Entretanto, a análise experimental também evidencia que o tempo computacional não depende exclusivamente do número de variáveis ou restrições do modelo. Características estruturais do problema, tais como esparsidade, condicionamento numérico e complexidade da matriz KKT, possuem impacto direto no desempenho.

1.5 Conclusão

Os experimentos realizados demonstraram que o IPOPT apresentou elevada robustez e eficiência computacional, obtendo solução local em 100% das 44 instâncias avaliadas. A mediana inferior a 0,6 segundos evidencia a capacidade do método para resolver rapidamente a maioria dos problemas NLP considerados.

A principal limitação identificada está relacionada ao comportamento incomum do contador de iterações, que apresentou valor unitário em todas as execuções. Embora os resultados de convergência sejam positivos, recomenda-se uma validação adicional do processo de coleta dessa métrica, incluindo a inspeção dos logs internos do IPOPT e dos resíduos KKT.

De maneira geral, os resultados confirmam que o IPOPT constitui uma ferramenta computacional robusta para resolução de problemas de Programação Não Linear, sendo particularmente adequado para aplicações industriais e científicas que envolvam modelos contínuos de grande complexidade.

2 Análise de Desempenho do Solver Optim - AMPL-NLP Benchmark

2.1 Resumo Executivo e Taxa de Sucesso

O solver *Optim.jl* foi avaliado utilizando um conjunto de 47 problemas clássicos de Programação Não Linear (NLP), pertencentes ao benchmark de Mittelmann. Este conjunto de testes contempla diferentes características estruturais, incluindo problemas de pequeno, médio e grande porte, com diferentes níveis de não linearidade e complexidade computacional.

A distribuição dos resultados obtidos pelo solver apresentou o seguinte comportamento:

- Soluções classificadas como `LOCALLY_SOL`: 23 instâncias (48,9%);
- Falhas de execução classificadas como `OTHER_ERRC`: 24 instâncias (51,1%).

Embora aproximadamente metade das instâncias tenha retornado um status de solução local encontrada, a análise detalhada dos indicadores de execução revelou um comportamento atípico no processo iterativo do solver.

2.2 Análise do Processo Iterativo e Convergência

A avaliação dos registros de execução mostrou que todas as 47 instâncias apresentaram o mesmo padrão nos indicadores de desempenho:

- Número de iterações: 1;
- Tempo efetivo do solver (*solver_time*): 0 segundos.

Esse comportamento é inconsistente com a dinâmica esperada de algoritmos clássicos de otimização não linear, nos quais a convergência normalmente ocorre após sucessivas atualizações do vetor de variáveis de decisão, avaliações da função objetivo e, quando disponível, cálculo de gradientes ou aproximações da Hessiana.

A ausência de evolução iterativa sugere que o processo de otimização pode ter sido interrompido prematuramente ou limitado por alguma configuração da execução. Entre as possíveis causas destacam-se:

1. **Restrição excessiva no número máximo de iterações:** o solver pode ter sido configurado com um limite reduzido de iterações (*max_iterations*), fazendo com que a execução fosse encerrada após a avaliação inicial.
2. **CrITÉrios de parada atingidos no ponto inicial:** dependendo das tolerâncias configuradas e das características do problema, o algoritmo pode interpretar o ponto inicial como satisfatório para os critérios de convergência.

3. **Problemas na avaliação inicial das funções:** para as instâncias classificadas como `OTHER_ERRC`, as falhas podem estar relacionadas à impossibilidade de avaliar corretamente a função objetivo, restrições ou derivadas no ponto inicial fornecido.
4. **Problemas na interface de modelagem:** erros na construção do modelo matemático, especialmente envolvendo expressões não diferenciáveis, variáveis mal definidas ou incompatibilidades na representação das funções, podem interromper a execução antes da fase iterativa.

Dessa forma, os resultados obtidos devem ser interpretados como um diagnóstico da configuração experimental do solver, e não como uma avaliação definitiva da capacidade computacional do Optim em problemas NLP.

2.3 Análise dos Tempos Computacionais

Como o tempo registrado especificamente pelo solver foi igual a zero para todas as instâncias, a variável *total_time* representa predominantemente o custo computacional associado ao carregamento das instâncias, construção das estruturas internas e preparação do modelo matemático.

Para as instâncias classificadas como `LOCALLY_SOL`, observou-se:

- Tempo total entre 0,026 s e 0,448 s;
- Execução extremamente rápida;
- Ausência de processo iterativo significativo.

Esse comportamento reforça a hipótese de que a solução foi retornada imediatamente após a etapa inicial de avaliação.

Por outro lado, as instâncias classificadas como `OTHER_ERRC` apresentaram maior custo computacional, alcançando valores superiores a 46 segundos, como observado no problema *camshape100*. Esse aumento está associado provavelmente ao custo de inicialização, processamento das expressões matemáticas ou tentativa de avaliação das estruturas diferenciais antes da interrupção da execução.

2.4 Resumo Estatístico dos Resultados

Tabela 2: Resumo estatístico do desempenho do solver Optim no benchmark NLP.

Status	Quantidade	Percentual	Tempo Total (s)	Iterações Médias
LOCALLY_SOL	23	48,9%	0,026–0,448	1,0
OTHER_ERRC	24	51,1%	1,733–46,21	1,0

2.5 Discussão Técnica e Recomendações

Os resultados obtidos indicam que a configuração experimental utilizada não permitiu explorar adequadamente o comportamento iterativo do solver Optim. Embora algumas instâncias tenham retornado soluções classificadas como locais, os indicadores de execução demonstram que o algoritmo não apresentou o processo esperado de refinamento da solução.

Para uma avaliação mais representativa recomenda-se:

- **Revisão dos parâmetros de execução:** verificar os valores configurados para número máximo de iterações, avaliações da função objetivo e critérios de convergência.
- **Validação das derivadas:** garantir que os gradientes utilizados pelo solver estejam corretamente definidos, seja por diferenciação automática, diferenciação analítica ou aproximações numéricas.
- **Análise dos pontos iniciais:** avaliar se os pontos iniciais fornecidos pelos benchmarks são compatíveis com as restrições e domínio das funções matemáticas.
- **Ajuste das tolerâncias numéricas:** revisar parâmetros relacionados à precisão de convergência, evitando encerramentos prematuros.
- **Comparação com outros solvers NLP:** realizar uma comparação utilizando solvers especializados, como IPOPT, MadNLP ou outros métodos baseados em pontos interiores, permitindo avaliar corretamente a dificuldade das instâncias.

2.6 Conclusão

Conclui-se que os resultados obtidos pelo Optim representam principalmente uma análise da configuração de execução adotada. A baixa quantidade de iterações e a ausência de tempo efetivo de otimização indicam a necessidade de uma etapa adicional de validação experimental antes de realizar comparações de desempenho com outros solvers de Programação Não Linear.

3 Análise de Desempenho do UNOSolver - AMPL-NLP Benchmark

3.1 Resumo Executivo e Taxa de Sucesso

O *UNOSolver* foi avaliado utilizando o conjunto de problemas de Programação Não Linear (NLP) pertencentes ao benchmark de Mittelman. O conjunto experimental compreendeu problemas com diferentes níveis de dimensionalidade, não linearidade e complexidade de restrições, permitindo avaliar a robustez e a capacidade de convergência do método.

Considerando o critério de parada estabelecido pelo limite máximo de execução (*time limit*) de aproximadamente 30 segundos por instância, foram obtidos os seguintes resultados:

- **Soluções locais encontradas (LOCALLY_SOL):** 35 problemas, correspondendo a uma taxa de sucesso de aproximadamente 74,5%;
- **Interrupção por limite de tempo (TIME_LIMIT):** 12 problemas, correspondendo a aproximadamente 25,5% do conjunto avaliado.

Os resultados indicam que o UNOSolver apresentou desempenho consistente para a maior parte das instâncias analisadas, sendo capaz de obter soluções locais viáveis em aproximadamente três quartos dos problemas submetidos. Entretanto, as instâncias de maior porte ou com maior complexidade estrutural evidenciaram limitações relacionadas ao custo computacional necessário para atingir os critérios de convergência.

3.2 Análise do Comportamento Computacional

Uma característica relevante observada durante os experimentos está relacionada ao comportamento das métricas de execução. As colunas *solver_time* e *total_time* apresentam valores praticamente idênticos, indicando que o custo computacional está concentrado no processo interno do solucionador. Dessa forma, o tempo associado à interface de execução, pré-processamento ou comunicação com o modelo matemático representa uma parcela desprezível do tempo total.

Entretanto, observa-se que a variável referente ao número de iterações (*iterations*) permanece constante com valor igual a 1 para todas as instâncias avaliadas. Esse comportamento não é compatível com a dinâmica tradicional de algoritmos de otimização não linear, nos quais são esperadas múltiplas iterações envolvendo atualizações de variáveis, avaliação de gradientes e resolução de subproblemas.

Uma possível explicação é que o UNOSolver esteja reportando apenas a iteração externa principal do algoritmo, enquanto os processos internos de otimização, tais como avaliações de funções, resolução de sistemas lineares, etapas de globalização ou subproblemas associados ao método SQP (*Sequential Quadratic Programming*), não estejam sendo contabilizados nessa métrica.

Portanto, neste benchmark específico, o número de iterações reportado não deve ser interpretado como uma medida direta do esforço computacional realizado pelo solver. O tempo de execução apresenta-se como uma métrica mais representativa para análise comparativa.

3.3 Desempenho nas Instâncias Resolvidas

As instâncias classificadas como **LOCALLY_SOL** apresentaram comportamento satisfatório em relação ao tempo computacional e à qualidade das soluções encontradas.

Problemas de menor complexidade, como *camshape*, *catmix* e *chain*, foram solucionados em poucos segundos, demonstrando eficiência do método quando aplicado a modelos com menor dimensionalidade.

Para problemas progressivamente maiores, como *minsurf*, *pinene*, *polygon* e *robot100*, observou-se aumento gradual do tempo computacional, atingindo valores próximos ao limite máximo estabelecido. O problema *robot100*, por exemplo, apresentou tempo de execução próximo de 29,35 segundos, indicando que o solver permaneceu capaz de evoluir a solução até próximo do limite computacional imposto.

Outro aspecto importante é a qualidade numérica das soluções obtidas. Para a maioria das instâncias resolvidas, os valores da função objetivo permaneceram em ordens de grandeza extremamente reduzidas (10^{-16} a 10^{-26}), indicando forte redução do resíduo associado ao problema e aproximação adequada das condições de otimalidade.

3.4 Análise das Instâncias Limitadas pelo Tempo

Do conjunto avaliado, 12 problemas atingiram o critério de parada por tempo máximo (TIME.LIMIT). Entre eles destacam-se:

- *robot200* e *robot400*;
- problemas das famílias *rocket*;
- problemas da família *steering*;
- problemas *torsion*;
- problema *tetra*.

Essas instâncias apresentam características que elevam significativamente a complexidade computacional, como maior número de variáveis, aumento da densidade das restrições e maior dificuldade na obtenção de uma região viável.

Diferentemente dos casos resolvidos, nos quais os valores da função objetivo foram reduzidos para escalas próximas de zero, algumas instâncias interrompidas apresentaram valores ainda elevados. Como exemplo, o problema *torsion50* apresentou valor objetivo aproximadamente igual a 133,13, indicando que o algoritmo provavelmente foi interrompido antes de completar o processo de redução da função objetivo ou antes de atingir satisfatoriamente as condições de viabilidade.

Esse comportamento evidencia que, embora o UNOSolver seja eficiente para uma grande parcela dos problemas avaliados, existe uma limitação de escalabilidade quando aplicado a modelos NLP de maior complexidade.

3.5 Resumo Estatístico dos Resultados

A Tabela 3 apresenta uma síntese dos resultados obtidos pelo UNOSolver.

Tabela 3: Resumo do desempenho do UNOSolver no benchmark de Mittelman.

Status	Quantidade	Exemplos	Tempo de Execução (s)
LOCALLY_SOL	35	camshape, elec75, robot100	0,17 – 29,35
TIME_LIMIT	12	robot400, rocket400, steering400, torsion50	30,03 – 30,31

3.6 Conclusão da Avaliação do UNOSolver

Os resultados obtidos demonstram que o UNOSolver apresenta desempenho competitivo para problemas NLP de pequeno e médio porte, alcançando uma taxa de sucesso de aproximadamente 74,5%. O solver mostrou capacidade de encontrar soluções locais com elevada precisão numérica, evidenciada pelos baixos valores da função objetivo obtidos nas instâncias convergidas.

Entretanto, os experimentos também revelaram limitações relacionadas à escalabilidade computacional. Problemas com maior dimensionalidade ou estrutura mais complexa frequentemente atingiram o limite máximo de tempo, indicando que o custo computacional associado às etapas internas do algoritmo cresce de forma significativa nesses cenários.

Dessa forma, o UNOSolver apresenta-se como uma alternativa eficiente para uma faixa relevante de problemas NLP, especialmente quando a prioridade é obter soluções locais precisas em tempo computacional moderado. Para aplicações industriais de maior escala, recomenda-se avaliar estratégias complementares, como ajustes de parâmetros, técnicas de pré-condicionamento ou comparação com solvers especializados em otimização não linear de larga escala, como IPOPT e MadNLP.

4 Análise de Desempenho do Solver MadNLP - AMPL-NLP Benchmark

4.1 Resumo Executivo e Taxa de Sucesso

O solver **MadNLP** foi avaliado utilizando o conjunto de instâncias do benchmark de *Mittelman* para problemas de Programação Não Linear (*Nonlinear Programming* – NLP), com o objetivo de analisar sua capacidade de convergência, robustez numérica e desempenho computacional.

Os resultados obtidos demonstram um comportamento altamente consistente, com **47 problemas resolvidos com sucesso**, todos classificados com o status **LOCALLY_SOL**, indicando que o algoritmo foi capaz de encontrar soluções localmente ótimas para todas as instâncias avaliadas.

A taxa de sucesso obtida pelo solver pode ser calculada por:

$$Taxa de Sucesso = \frac{N_{LOCALLY_SOL}}{N_{Total}} \times 100 \quad (3)$$

Substituindo os valores observados:

$$TaxadeSucesso = \frac{47}{47} \times 100 = 100\% \quad (4)$$

Além disso, não foram observados casos classificados como `TIME_LIMIT` ou `OTHER_ERRC`, indicando elevada robustez operacional do MadNLP para o conjunto de problemas analisado.

4.2 Análise do Comportamento das Iterações

Um aspecto relevante identificado nos resultados refere-se ao comportamento da variável *iterations*, que apresentou valor constante igual a 1 para todas as instâncias avaliadas.

Esse comportamento não deve ser interpretado como ausência de iterações do processo de otimização. O MadNLP é baseado em métodos de *Pontos Interiores* (*Interior Point Methods*), nos quais a solução é obtida através de um processo iterativo envolvendo:

- atualização do parâmetro de barreira;
- resolução dos sistemas lineares associados às condições de Karush-Kuhn-Tucker (KKT);
- cálculo das direções de busca;
- estratégias de restauração da factibilidade.

Dessa forma, o valor registrado na tabela deve ser interpretado como uma característica da interface de coleta dos resultados ou do *wrapper* utilizado no processo de benchmarking, onde a chamada completa ao solver é contabilizada como uma única execução.

A análise conjunta com o tempo de processamento do solver (*solver_time*) confirma a existência de processamento computacional efetivo. Como exemplo, a instância *camshape100* apresentou:

$$t_{solver} = 24,17s \quad (5)$$

evidenciando que o algoritmo realizou o processo interno de otimização antes da obtenção da solução final.

Portanto, recomenda-se que análises futuras utilizem os registros internos do MadNLP para obter o número real de iterações, evolução do parâmetro de barreira e comportamento da convergência numérica.

4.3 Avaliação do Desempenho Computacional

A comparação entre as métricas *total_time* e *solver_time* demonstra que o custo computacional é predominantemente associado ao núcleo de otimização.

A relação observada pode ser representada aproximadamente por:

$$t_{total} \approx t_{solver} \quad (6)$$

indicando baixo custo adicional relacionado às etapas externas ao algoritmo, tais como:

- construção da formulação matemática;
- comunicação entre a interface e o solver;
- processamento da solução retornada.

A instância *camshape100* apresentou o maior custo computacional do conjunto analisado, com:

$$t_{total} = 42,38s \quad (7)$$

e:

$$t_{solver} = 24,17s \quad (8)$$

Esse comportamento indica uma maior dificuldade numérica durante o processo de convergência, podendo estar associado às características específicas da formulação, como:

- condicionamento desfavorável da matriz KKT;
- maior esforço computacional nas fatorações internas;
- necessidade de etapas adicionais de restauração.

Entretanto, outras instâncias pertencentes à mesma família, como *camshape200*, *camshape400* e *camshape800*, apresentaram tempos significativamente inferiores. Esse resultado evidencia que a dificuldade computacional não depende exclusivamente do tamanho da instância, mas também das características matemáticas da formulação.

4.4 Precisão das Soluções Obtidas

Os valores finais da função objetivo demonstram elevada precisão numérica nas soluções encontradas pelo MadNLP.

Os resultados permaneceram na faixa:

$$10^{-8} \leq f(x) \leq 10^{-7} \quad (9)$$

indicando que o solver atingiu soluções com elevado grau de precisão, atendendo aos critérios de:

- viabilidade primal;
- consistência dual;

- condições de convergência associadas ao método de pontos interiores.

A uniformidade dos valores obtidos demonstra estabilidade numérica para diferentes classes de problemas presentes no benchmark de Mittelman.

4.5 Resumo dos Resultados

A Tabela 4 apresenta um resumo geral do desempenho do MadNLP.

Tabela 4: Resumo do desempenho do solver MadNLP no benchmark de Mittelman.

Status Final	Quantidade	Exemplos	Observação
LOCALLY_SOL	47	camshape100, robot400, torsion500	Todas convergiram
TIME_LIMIT	0	–	Nenhuma interrupção
OTHER_ERRC	0	–	Nenhum erro operacional

4.6 Considerações Finais

Os resultados obtidos demonstram que o MadNLP apresentou comportamento altamente robusto para o conjunto de problemas NLP avaliados, alcançando **100% de taxa de convergência** e elevada precisão nas soluções finais.

O desempenho observado confirma a capacidade do solver em tratar diferentes classes de problemas não lineares, incluindo formulações de maior complexidade estrutural, como as famílias *robot*, *rocket*, *steering* e *torsion*.

Apesar da limitação observada na métrica de iterações disponibilizada pelo benchmark, os tempos computacionais registrados confirmam a execução efetiva do processo iterativo interno do método de pontos interiores.

Como trabalho futuro, recomenda-se a integração dos logs internos do MadNLP ao processo de benchmarking, permitindo uma análise mais detalhada da dinâmica de convergência, incluindo:

- número real de iterações;
- evolução do parâmetro de barreira;
- comportamento das condições KKT;
- custo computacional das fatorações internas.

Essa extensão permitirá uma comparação mais rigorosa entre os diferentes solvers NLP avaliados neste estudo.

5 Análise de Desempenho do Solver IPOPT no Benchmark COCONUT

5.1 Resumo Executivo e Taxa de Sucesso

O solver *Interior Point OPTimizer* (IPOPT), baseado no método de pontos interiores com estratégia de barreira logarítmica, foi avaliado utilizando um conjunto de instâncias de Programação Não Linear (NLP) provenientes da biblioteca COCONUT. Este benchmark é caracterizado pela presença de problemas altamente não convexos, funções objetivo complexas e restrições não lineares com diferentes níveis de dificuldade numérica.

A análise dos resultados obtidos demonstra uma divisão equilibrada entre convergência e falhas de execução. Do total de problemas avaliados, 23 instâncias apresentaram solução válida, classificadas como **LOCALLY_SOL**, correspondendo a uma taxa de sucesso de aproximadamente 48,9%. Nesses casos, o IPOPT conseguiu satisfazer os critérios de convergência estabelecidos, encontrando soluções localmente ótimas dentro das tolerâncias numéricas configuradas.

Por outro lado, 24 problemas apresentaram falhas durante o processo de resolução, classificados como **OTHER_ERROR** ou **OTHER_ERRC**, representando aproximadamente 51,1% do conjunto analisado. Esses resultados indicam que, embora o IPOPT apresente elevada eficiência em determinadas classes de problemas, sua robustez é limitada em formulações com elevada sensibilidade numérica ou forte característica não convexa.

Tabela 5: Resumo dos resultados obtidos pelo IPOPT no benchmark COCONUT.

Categoria	Quantidade	Percentual	Status
LOCALLY_SOL	23	48,9%	Solução encontrada
OTHER_ERROR/OTHER_ERRC	24	51,1%	Falha de execução
Total	47	100%	–

5.2 Análise do Comportamento Computacional

A análise detalhada dos registros de execução revelou um comportamento inconsistente nos indicadores computacionais coletados. Observou-se que o número de iterações reportado permaneceu constante em praticamente todas as instâncias avaliadas, apresentando valor igual a 1, independentemente da complexidade do problema ou do resultado final obtido.

Além disso, o tempo atribuído exclusivamente ao solver (*solver time*) apresentou valores próximos de zero, enquanto o tempo total de execução (*total time*) apresentou crescimento significativo principalmente nos casos classificados como falha. Foram observados tempos totais variando aproximadamente entre 1,7 segundos e 46,2 segundos nas instâncias que não obtiveram convergência.

Esse comportamento sugere que os valores extraídos não representam adequadamente o desempenho interno do algoritmo IPOPT, indicando a existência de uma limitação na camada de integração entre o solver e o ambiente de execução utilizado. Possivelmente, parte significativa do tempo computacional foi consumida durante etapas de inicialização, carregamento da formulação matemática, construção das estruturas esparsas ou avaliação inicial das funções e derivadas, antes da efetiva execução do algoritmo de otimização.

Dessa forma, os resultados relacionados ao contador de iterações e tempo interno do solver devem ser interpretados com cautela, pois podem estar influenciados pelo processo de coleta das métricas através da interface JuMP/MathOptInterface.

5.3 Comportamento do IPOPT Frente às Características do Benchmark COCONUT

A biblioteca COCONUT contém problemas reconhecidamente difíceis para métodos determinísticos de otimização local, principalmente devido à presença de não convexidade, múltiplos mínimos locais, funções altamente não lineares e elevada dependência da estimativa inicial.

Dentro desse cenário, o IPOPT apresentou desempenho satisfatório em problemas de complexidade moderada e formulações matemáticas com melhor condicionamento numérico. Entre as instâncias solucionadas destacam-se:

- `camshape200`;
- `elec50`;
- `polygon50`;
- `robot400`.

Nessas instâncias, o método de barreira conseguiu identificar rapidamente uma região factível e conduzir o processo iterativo até uma solução localmente ótima, apresentando tempos reduzidos de processamento.

Entretanto, as principais dificuldades ocorreram em problemas com maior sensibilidade numérica ou dependência significativa da solução inicial, como:

- `camshape100`;
- `pinene100`;
- `rocket400`.

Nessas situações, a necessidade do IPOPT por avaliações consistentes do gradiente e da matriz Hessiana pode representar uma limitação quando existem regiões mal condicionadas, descontinuidades ou dificuldades na aproximação das derivadas.

5.4 Resumo Estatístico dos Resultados

A Tabela 6 apresenta a consolidação dos resultados obtidos pelo IPOPT.

Tabela 6: Resumo estatístico do desempenho do IPOPT no benchmark COCONUT.

Status	Quantidade	Percentual	Exemplos	Tempo Total (s)
LOCALLY_SOL	23	48,9%	camshape200, elec50	0,026 – 0,448
OTHER_ERROR	24	51,1%	camshape100, pinene100	1,733 – 46,213

5.5 Discussão Técnica e Recomendações

Os resultados indicam que o IPOPT apresenta elevada eficiência computacional quando aplicado a problemas NLP com boa estrutura numérica e regiões factíveis bem definidas. Nas instâncias em que ocorreu convergência, o solver apresentou tempos de execução reduzidos, evidenciando a eficiência do método de pontos interiores para problemas de grande escala com derivadas disponíveis.

Entretanto, para uma comparação quantitativa justa com outros solvers avaliados neste trabalho, como MadNLP e UNOSolver, recomenda-se aprimorar o mecanismo de extração das métricas de desempenho. A contagem real de iterações deve ser obtida diretamente a partir das informações internas do IPOPT, utilizando funções específicas da interface JuMP ou arquivos de saída gerados pelo próprio solver.

Uma análise mais precisa das iterações, avaliações da função objetivo, avaliações do gradiente e comportamento da barreira permitirá uma comparação mais representativa entre os diferentes métodos.

5.6 Conclusão

O desempenho do IPOPT no benchmark COCONUT demonstrou um comportamento característico de métodos locais baseados em pontos interiores. Apesar de apresentar uma taxa global de sucesso de aproximadamente 48,9%, o solver mostrou excelente desempenho computacional nas instâncias convergentes, resolvendo problemas em frações de segundo.

As falhas observadas estão associadas principalmente às características intrínsecas das instâncias avaliadas, envolvendo não convexidade elevada, sensibilidade à estimativa inicial e dificuldades no tratamento numérico das derivadas.

Portanto, os resultados confirmam que o IPOPT permanece uma ferramenta robusta e eficiente para problemas NLP de grande escala, porém sua aplicação em benchmarks globais como o COCONUT depende fortemente da qualidade da formulação matemática, das informações derivativas disponíveis e das condições iniciais fornecidas ao algoritmo.

6 Análise de Desempenho do Solver MadNLP no Benchmark COCONUT

6.1 Resumo Executivo e Taxa de Sucesso

O solver *MadNLP* foi avaliado utilizando um subconjunto composto por 47 problemas de Programação Não Linear (NLP - *Nonlinear Programming*) provenientes da biblioteca de testes COCONUT. O MadNLP é um resolvidor baseado no método de pontos interiores com estratégia de filtro (*filter line-search*), desenvolvido nativamente no ecossistema Julia, com foco em problemas de grande escala contendo estruturas esparsas.

Os resultados experimentais demonstraram um comportamento altamente robusto e consistente durante a resolução das instâncias avaliadas. Todas as 47 instâncias foram resolvidas com sucesso, atingindo uma solução localmente ótima segundo os critérios internos de convergência do solver.

A Tabela 7 apresenta o resumo estatístico dos resultados obtidos.

Tabela 7: Resumo do desempenho do MadNLP no benchmark COCONUT.

Categoria	Quantidade	Percentual	Observação
LOCALLY_SOL	47	100%	Solução local encontrada
TIME_LIMIT	0	0%	Nenhum limite excedido
OTHER_ERROR	0	0%	Nenhum erro de execução
Falhas de memória	0	0%	Nenhuma ocorrência registrada

O resultado obtido evidencia uma elevada capacidade de convergência do MadNLP para problemas NLP com diferentes níveis de complexidade, indicando estabilidade numérica e adequada implementação dos mecanismos de busca e restauração de viabilidade.

6.2 Análise do Comportamento Computacional

6.2.1 Relação entre Tempo Computacional e Iterações

A análise dos arquivos de log gerados durante a execução revelou um comportamento relevante relacionado ao registro das métricas de desempenho. Diferentemente de algumas implementações avaliadas anteriormente, nas quais o tempo computacional não era corretamente contabilizado, o MadNLP apresentou medições consistentes de tempo de processamento.

O tempo total de solução (*total time*) apresentou variação significativa entre as instâncias analisadas, variando aproximadamente entre:

$$0,03\text{segundos} \leq t_{exec} \leq 42,38\text{segundos}$$

Essa variação está diretamente relacionada à complexidade estrutural dos problemas, número de variáveis, quantidade de restrições e características da matriz Jacobiana/Hessiana associada.

Entretanto, observou-se que a métrica referente ao número de iterações permaneceu constante com valor igual a 1 em todas as instâncias analisadas. Este comportamento não representa uma convergência real em apenas uma iteração, mas sim uma limitação no processo de extração das informações através da interface JuMP/MathOptInterface.

O contador exportado corresponde apenas ao estado inicial disponibilizado pelo *wrapper*, não refletindo o histórico completo de iterações internas realizadas pelo algoritmo de pontos interiores do MadNLP.

Portanto, a interpretação correta dos resultados deve considerar que:

- o tempo computacional apresenta comportamento coerente com a dificuldade dos problemas;
- o solver realizou efetivamente o processo iterativo interno;
- a métrica de iterações necessita ser coletada diretamente através dos mecanismos nativos do MadNLP.

6.3 Precisão Numérica das Soluções Obtidas

A análise dos valores finais das funções objetivo demonstrou elevada precisão numérica nas soluções encontradas.

Para a maioria das instâncias avaliadas, os valores finais permaneceram próximos da escala de:

$$f(x^*) \approx 10^{-7} a 10^{-8}$$

indicando que os critérios de parada relacionados à viabilidade primal, viabilidade dual e complementaridade foram satisfeitos adequadamente.

Esse comportamento demonstra que o MadNLP apresentou controle eficiente dos erros numéricos, mesmo em problemas contendo não linearidades complexas e estruturas esparsas.

6.4 Resultados Consolidados

A Tabela 8 apresenta uma visão consolidada do desempenho do solver.

Tabela 8: Resultados agregados do MadNLP no benchmark COCONUT.

Status	Número de Problemas	Percentual	Exemplos
LOCALLY_SOL	47	100%	camshape, robot400, torsion50, steering400
Falhas/Erros	0	0%	Nenhum

Embora o contador de iterações tenha permanecido fixo em 1, esse comportamento está associado exclusivamente ao mecanismo de coleta dos dados, não representando uma limitação algorítmica do MadNLP.

6.5 Discussão Técnica e Comparação de Robustez

O desempenho observado posiciona o MadNLP como um dos métodos mais robustos entre os solvers avaliados no ambiente experimental considerado.

A taxa de sucesso de 100% demonstra uma elevada capacidade de tratamento de problemas NLP heterogêneos, incluindo instâncias com forte acoplamento entre variáveis, restrições não lineares complexas e estruturas esparsas.

Destaca-se particularmente o desempenho em famílias reconhecidamente desafiadoras, como:

- problemas da família *robot*;
- problemas *rocket*;
- problemas da família *steering*.

Essas classes apresentam características que frequentemente provocam dificuldades em métodos baseados em derivadas, principalmente devido ao condicionamento numérico e à complexidade da região factível.

6.6 Conclusões e Trabalhos Futuros

Os experimentos realizados indicam que o MadNLP apresenta elevada robustez, estabilidade numérica e capacidade de convergência para problemas de Programação Não Linear.

O solver obteve:

- taxa de sucesso de 100%;
- ausência completa de falhas de execução;
- tempos computacionais coerentes com a complexidade das instâncias;
- soluções finais com elevada precisão numérica.

Como trabalho futuro, recomenda-se o aprimoramento do mecanismo de coleta das métricas internas do solver. Uma análise mais detalhada utilizando os registros nativos do MadNLP permitiria recuperar informações como:

- número real de iterações do método de pontos interiores;
- evolução da função barreira;
- comportamento dos resíduos primal e dual;
- número de avaliações de gradiente e Hessiana.

A obtenção dessas informações possibilitaria uma análise mais aprofundada da eficiência algorítmica e permitiria comparações quantitativas mais rigorosas entre diferentes resolvedores NLP.