

Análise Comparativa: Machine Scheduling × Job Shop × Flow Shop

Solver: HiGHS (open-source) · Modelagem: Julia + JuMP · Trabalho 02

Leandro Correia Santos de Oliveira - Matrícula: 3260176 ¹

¹ UFAM - Departamento de Engenharia Elétrica · Manaus - AM, Brasil



Figura 1 — Indicadores-chave do experimento (48 instâncias, 3 problemas, solver HiGHS).

Introdução

Este trabalho apresenta uma análise comparativa de três classes de problemas de scheduling resolvidos via MILP com o solver HiGHS (Brasil) no ambiente Julia/JuMP. Os problemas avaliados são: Machine Scheduling com uma máquina (1|rj|ΣTj), Job Shop (JSP) e Flow Shop (FSP). São apresentados o tempo de execução, gap de otimalidade, variáveis binárias e status do solver para 48 instâncias no total.

Observa-se empiricamente que a dificuldade computacional está mais associada à estrutura combinatória dos problemas do que ao tamanho da instância, um ponto que será discutido ao longo do relatório.

Configuração Experimental

Parâmetro	Machine Scheduling	Job Shop	Flow Shop
Limite de tempo	60 s	60 s	60 s
Gap (mip_rel_gap)	10%	20%	10%
Threads	4	4	4

Parâmetro	Machine Scheduling	Job Shop	Flow Shop
Presolve / Paralelo	on / on	on / on	on / on
Esforço heurístico	0,50	0,30	0,30
Warm-start	Melhor(EDD/FIFO/SPT)	Greedy	NEH
Big-M	$\max(r) + \sum p$	$\sum \sum p_{jk}$	$\sum P[:, 1:k]$
Binárias	$C(n, 2)$	$C(n, 2) \times m$	$C(n, 2) - \text{prop. FSP}$

Tabela 1 — Parâmetros do solver HiGHS por problema.

idade é definido como $\text{gap}(\%) = |\text{UB} - \text{LB}| / |\text{UB}| \times 100$, onde UB é o melhor inteiro encontrado e LB é o melhor bound inferior. Quando $\text{gap} < \text{threshold}$; caso contrário, TIME_LIMIT. Essa distinção entre qualidade da solução (gap_ref) e qualidade da prova é central para a interpretação dos resultados, especialmente em problemas como o Job Shop.

Resumo Comparativo

Resumo das Instâncias




Figura 2 — Distribuição de status (OPTIMAL / TIME_LIMIT) por problema.




Figura 3 — Status geral consolidado: 17 OPTIMAL (35,4%) e 31 TIME_LIMIT (64,6%) em 48 instâncias.

mpo




Figura 4 — Gap médio de otimalidade por problema e status. Linha tracejada: referência de 15%.




Figura 5 — Distribuição do tempo de execução por problema. Linha vermelha: limite de 60 s.

Scheduling ($1|r_j|\Sigma T_j$)

Minimiza a tardiness total de n jobs em uma única máquina, cada job com tempo de liberação (r_j), duração (p_j) e data de entrega (d_j). A formulação MILP usa $C(n,2)$ variáveis binárias para ordenação de pares.

le Gantt — inst_book (n=7)

O Gantt ilustra a solução MILP para a instância inst_book (7 jobs, 1 máquina). Barras verdes indicam jobs concluídos no prazo; barras vermelhas indicam jobs com atraso. A solução MILP obteve tardiness total = 16, contra 27 da heurística EDD.




Figura 7 — Gráfico de Gantt para inst_book (Machine Scheduling). Solução MILP: tardiness = 16; EDD: tardiness = 27.

amanho da Instância




Figura 8 — Gap de otimalidade vs número de jobs. Limiar de escalabilidade em $n = 11/12$.




Figura 9 — Melhoria percentual do MILP sobre a melhor heurística (EDD/FIFO/SPT) por instância.

os Detalhados

Instância	n	EDD	FIFO	SPT	Best-H	MILP	Gap (%)	Binárias	Tempo (s)	Status
inst_book	7	1	27	31	51	27	16.00%	9.9	21.00	0.45
inst_n05_s01	5	1	7	9	54	7	7.00%	0	10.00	0.02
inst_n05_s02	5	1	15	19	15	15	15.00%	4.76	10.00	0.17
inst_n05_s03	5	1	3	4	20	3	3.00%	0	10.00	0.02
inst_n07_s01	7	1	58	42	99	42	38.00%	9.47	21.00	0.71
inst_n07_s02	7	1	31	40	77	31	31.00%	9.82	21.00	3.1
inst_n07_s03	7	1	30	36	56	30	26.00%	7.69	21.00	0.42
inst_n09_s01	9	1	29	38	62	29	26.00%	9.62	36.00	1.1

Instância	n	EDD	FIFO	SPT	Best-H	MILP	Gap (%)	Binárias	Tempo (s)	Status
inst_n09_s02	9	1	94	83	64	64	56.00%	9.97	36.00	10.25
inst_n09_s03	9	1	39	47	43	39	34.00%	37.8	36.00	60.05
inst_n11_s01	11	1	43	46	134	43	16.00%	10	55.00	13.79
inst_n11_s02	11	1	113	98	229	98	62.00%	38.61	55.00	60.05
inst_n11_s03	11	1	223	178	180	178	116.00%	86.03	55.00	60.06
inst_n13_s01	13	1	146	116	213	116	73.00%	70.29	78.00	60.04
inst_n13_s02	13	1	264	214	404	214	113.00%	77.01	78.00	60.04
inst_n13_s03	13	1	103	82	277	82	71.00%	35.02	78.00	60.07
inst_n15_s01	15	1	187	289	512	187	157.00%	86.62	105.00	60.05
inst_n15_s02	15	1	236	250	507	236	139.00%	92.63	105.00	60.07
inst_n15_s03	15	1	162	139	224	139	69.00%	67.6	105.00	60.04
inst_n17_s01	17	1	275	379	696	275	212.00%	88.84	136.00	60.09
inst_n17_s02	17	1	273	232	599	232	212.00%	94.63	136.00	60.09
inst_n17_s03	17	1	225	189	658	189	127.00%	93.14	136.00	60.09
inst_n19_s01	19	1	434	396	1013	396	325.00%	95.58	171.00	60.07
inst_n19_s02	19	1	290	207	491	207	127.00%	100	171.00	60.06
inst_n19_s03	19	1	313	344	656	313	265.00%	95.48	171.00	60.09
inst_n21_s01	21	1	235	301	746	235	225.00%	94.17	210.00	60.08
inst_n21_s02	21	1	367	336	743	336	256.00%	100	210.00	60.1
inst_n21_s03	21	1	435	297	801	297	229.00%	94.59	210.00	60.09
inst_n24_s01	24	1	241	255	776	241	165.00%	100	276.00	60.12
inst_n24_s02	24	1	377	380	903	377	281.00%	99.64	276.00	60.11
inst_n24_s03	24	1	415	494	1053	415	333.00%	98.35	276.00	60.09

Tabela 2 — Resultados Machine Scheduling com coluna de variáveis binárias. Verde ≤ 5%, cinza ≤ 20%, laranja ≤ 50%, vermelho > 50%.

Job Scheduling (JSP)

o makespan (Cmax) de n jobs em m máquinas, cada job com rota própria. A formulação usa $C(n,2) \times m$ variáveis binárias - problemas. Foram avaliadas 10 instâncias do benchmark JSBLIB (famílias abz, ft, la, orb).




Figura 10 — JSP: Cmax obtido pelo MILP versus ótimo da literatura. ✓ = OPTIMAL.




Figura 11 — JSP: gap interno do solver por instância. Linha tracejada: threshold de 20%.

os Detalhados

Instância	Jobs	Máqs.	Ótimo	Cmax	Gap Ref. (%)	Gap MILP (%)	Binárias	Tempo (s)	Status
abz5	10	10	1234	1261	2.19%	22.07%	450	60.03	TIME_LIMIT
abz6	10	10	943	998	5.83%	15.00%	450	32.29	OPTIMAL
ft06	6	6	55	56	1.82%	12.76%	90	0.23	OPTIMAL
ft10	10	10	930	1070	15.05%	32.34%	450	60.06	TIME_LIMIT
ft20	20	5	1165	1364	17.08%	65.64%	950	60.15	TIME_LIMIT
la01	10	5	666	666	0.00%	23.05%	225	60.03	TIME_LIMIT
la02	10	5	655	689	5.19%	27.00%	225	60.04	TIME_LIMIT
la03	10	5	597	649	8.71%	31.14%	225	60.03	TIME_LIMIT

cia	Jobs	Máqs.	Ótimo	Cmax	Gap Ref. (%)	Gap MILP (%)	Binárias	Tempo (s)	Sta
	10	5	590	598	1.36%	14.88%	225	43.17	OPTI
	10	10	1059	1249	17.94%	37.73%	450	60.08	TIME_

Tabela 3 — Resultados Job Shop. Gap Ref.: desvio do ótimo de literatura. Binárias = $C(n,2) \times m$.

Job Shop Scheduling (FSP)

a o makespan de n jobs em m máquinas com ordem de processamento comum. A propriedade de ordem única foi explorada em 80–90%: apenas $C(n,2)$ binárias (em vez de $C(n,2) \times m$). O warm-start usa a heurística NEH. e, no Flow Shop, heurísticas especializadas são suficientes para obter soluções de alta qualidade, enquanto o MILP atua pra solução.




Figura 12 — FSP: redução de variáveis binárias explorando a propriedade estrutural de ordem única.




Figura 13 — FSP: Cmax da heurística NEH, solução MILP e bound inferior. ▲ = melhoria sobre NEH. ✓ = OPTIMAL.

os Detalhados

stância	Jobs	Máqs.	NEH_Cmax	MILP_Cmax	Bound	Gap MILP (%)	Gap vs NEH (%)	Binárias	Tempo (s)	Status
m_20j	20	10	292	292	292.0	23.97%	0.00%	190	60.27	TIME_LIM
n_10j	10	3	126	126	124.0	1.59%	0.00%	45	0.02	OPTIMA
n_20j	20	3	218	218	212.0	2.75%	0.00%	190	0.04	OPTIMA
n_10j	10	5	132	129	116.1	10.00%	2.27%	45	7.51	OPTIMA
n_20j	20	5	269	269	238.0	11.52%	0.00%	190	60.05	TIME_LIM
n_30j	30	5	327	327	318.0	2.75%	0.00%	435	0.19	OPTIMA

Instância	Jobs	Máqs.	NEH_Cmax	MILP_Cmax	Bound	Gap MILP (%)	Gap vs NEH (%)	Binárias	Tempo (s)	Status
n_10j	10	8	197	187	158.3	15.36%	5.08%	45	60.03	TIME_LIMIT

Tabela 4 — Resultados Flow Shop. Binárias = C(n,2) após redução pela propriedade FSP.

das Variáveis Binárias

ntar a análise estrutural, destaca-se que a variabilidade dos resultados entre os problemas pode ser interpretada em termos de estabilidade do desempenho do solver.

ariáveis binárias é o principal fator de custo computacional nos modelos MILP de scheduling. A Figura 14 consolida a análise do crescimento quadrático para MS e JSP, e a redução obtida no FSP pela exploração da propriedade estrutural de ordem única. A análise comparativa realizada permite compreender como a estrutura dos problemas influencia diretamente o desempenho computacional.




Figura 14 — Variáveis binárias por instância nos três problemas. FSP mostra redução de 80–90% (barras verdes vs cinzas).

Comparativa e Conclusão




Figura 15 — Taxa de instâncias OPTIMAL por problema: FSP 57,1%, MS 32,3%, JSP 30,0%.

Critério	MS	JSP	FSP	Melhor	Observação
Total instâncias	31	10	7	—	48 no total
OPTIMAL	10 (32,3%)	3 (30,0%)	4 (57,1%)	FSP	FSP explorou prop. estrutural
Gap médio OPTIMAL	7,1%	14,2%	4,3%	FSP	FSP com Big-M mais apertado por k
Gap médio TIME_LIMIT	79,0%	33,9%	16,9%	FSP	MS degrada rápido para $n > 11$
Tempo médio OPTIMAL	3,0 s	25,3 s	2,0 s	FSP	FSP tem menos binárias
Binárias ($n=10, m=5$)	45	225	45	MS/FSP	JSP 5× mais que FSP
Total binárias (todas)	3.315	3.740	1.140	FSP	FSP menor custo global
Limiar escala	$n \leq 11$	$n \leq 6 / m \leq 6$	$n \leq 30 / m \leq 5$	FSP	JSP mais restritivo

Critério	MS	JSP	FSP	Melhor	Observação
Qualidade heurística	Boa	Razoável	Ótima (NEH)	FSP	NEH ótima em 5/7 casos

Tabela 5 — Síntese comparativa final. Verde = melhor desempenho na dimensão avaliada.

arativa realizada permite compreender como a estrutura dos problemas influencia diretamente o desempenho computacional o e comparativa entre Machine Scheduling (MS), Job Shop Scheduling (JSP) e Flow Shop Scheduling (FSP) evidencia diferen desempenho computacional das formulações MILP avaliadas.

xperimentais suportam a ordem de dificuldade:

$$MS < FSP \ll JSP$$

o mostra que a dificuldade computacional depende menos do número de jobs e mais da estrutura combinatória do problema e Flow Shop apresentou melhor desempenho devido à propriedade de ordem única, que reduziu significativamente o número de v ações lineares mais fortes.

heduling foi o mais difícil, com crescimento $O(n^2 \cdot m)$ de variáveis binárias e forte interdependência entre decisões. O uso e axações fracas, dificultando a elevação do limitante inferior e mantendo gaps elevados. O Machine Scheduling apresentou bo pequenas, mas degradação abrupta após certo tamanho, indicando limitação na evolução do bound mesmo em estruturas ma o número de variáveis binárias é determinante, mas não suficiente: a qualidade da relaxação linear é igualmente crítica para

a-se uma assimetria fundamental no Branch-and-Bound: soluções viáveis são encontradas rapidamente, enquanto a prova lução do limitante inferior, processo significativamente mais lento — especialmente em formulações Big-M.

al desafio em problemas de scheduling via MILP não é encontrar boas soluções, mas construir formulações que produzam l fortes para permitir a certificação de otimalidade em tempo viável.

Metodológica

Julia utilizados (machine_scheduling_improved.jl, jobshop_improved.jl, flowshop_v3.jl) estão disponíveis para análise. Inc ísticas de warm-start, formulação MILP completa e execução em lote. Os códigos-fonte serão anexados ao relatório final.