Universidade Federal do Amazonas

Faculdade de Engenharia Elétrica e da Computação

Atividades - Disciplina Otimização

Aluno: Wesley Vitorino Teixeira

Prof Dr. Kenny Vinente dos Santos
kennyvinente@ufam.edu.br

Março
2026

1 Tópico 1

1.1

A small engineering consulting firm has 3 senior designers available to work on the firm's 4 current projects over the next 2 weeks. Each designer has 80 hours to split among the projects, and the following table shows the manager's scoring (0 = nil to 100 = perfect) of the capability of each designer to contribute to each project, along with his estimate of the hours that each project will require.

	Project			
Designer	1	2	3	4
1	90	80	10	50
2	60	70	50	65
3	70	40	80	85
Required	70	50	85	35

(a) Formulate an allocation LP to choose an optimal work assignment.

(b) Solve your model using JuMP.

Allocation LP Formulation

Let:

$$i \in \{1, 2, 3\} \quad \text{be the designers,}$$
$$j \in \{1, 2, 3, 4\} \quad \text{be the projects.}$$

Define the decision variables:

$$x_{ij} \geq 0 \quad = \text{number of hours designer } i \text{ allocates to project } j.$$

The capability scores are given by:

$$S = \begin{bmatrix} 90 & 80 & 10 & 50 \\ 60 & 70 & 50 & 65 \\ 70 & 40 & 80 & 85 \end{bmatrix}$$

The required hours for each project are:

$$r = [70,\ 50,\ 85,\ 35]$$

Each designer has at most 80 hours available.
The LP model is:

Objective Function

Maximize the total contribution score:

$$\max Z = 90x_{11}+80x_{12}+10x_{13}+50x_{14}+60x_{21}+70x_{22}+50x_{23}+65x_{24}+70x_{31}+40x_{32}+80x_{33}+85x_{34}$$

Constraints

Designer availability constraints Each designer can work at most 80 hours:

$$\begin{aligned} x_{11} + x_{12} + x_{13} + x_{14} &\leq 80 \\ x_{21} + x_{22} + x_{23} + x_{24} &\leq 80 \\ x_{31} + x_{32} + x_{33} + x_{34} &\leq 80 \end{aligned}$$

Project requirement constraints Each project must receive exactly its required number of hours:

$$\begin{aligned} x_{11} + x_{21} + x_{31} &= 70 \\ x_{12} + x_{22} + x_{32} &= 50 \\ x_{13} + x_{23} + x_{33} &= 85 \\ x_{14} + x_{24} + x_{34} &= 35 \end{aligned}$$

Nonnegativity constraints

$$x_{ij} \geq 0, \qquad \forall i = 1, 2, 3,\ \forall j = 1, 2, 3, 4$$

Compact Form

The model can also be written compactly as:

$$\begin{aligned} \max \quad & \sum_{i=1}^{3} \sum_{j=1}^{4} s_{ij} x_{ij} \\ \text{s.t.} \quad & \sum_{j=1}^{4} x_{ij} \leq 80, \qquad \forall i = 1, 2, 3 \\ & \sum_{i=1}^{3} x_{ij} = r_j, \qquad \forall j = 1, 2, 3, 4 \\ & x_{ij} \geq 0, \qquad \forall i = 1, 2, 3,\ \forall j = 1, 2, 3, 4 \end{aligned}$$

where s_{ij} is the capability score of designer i on project j, and r_j is the number of required hours for project j.

1.2

Prove the following results. Hint: Use the definition of convex functions, the first and second order characterizations.

(a) Univariate functions:

- Exponential function: e^{ax} is convex for any a over $\mathbb{R}$
- Power function: x^a is convex for $a \geq 1$ or $a \leq 0$ over $\mathbb{R}_+$ (nonnegative reals)
- Power function: x^a is concave for $0 \leq a \leq 1$ over $\mathbb{R}_+$
- Logarithmic function: $\log x$ is concave over $\mathbb{R}_{++}$

(b) Affine function: $a^T x + b$ is both convex and concave

(c) Quadratic function: $\frac{1}{2}x^T Q x + b^T x + c$ is convex provided that $Q \succeq 0$ (positive semidefinite)

(d) Least squares loss: $\|y - Ax\|_2^2$ is always convex (since $A^T A$ is always positive semidefinite)

PPGBE

Disciplina: Otimização
Professor: Dr. Kenny Vicente dos Santos
Aluno: Wesley Vitorino Teixeira

Tópico 1

1.2 Prove os seguintes resultados:

a) Função univariadas:

- Função exponencial: e^{ax} é convexa para qualquer a pertencente a $\mathbb{R}$.

- Primeira derivada: $f'(x): \frac{d}{dx}(e^{ax}) = a.e^{ax}$

- Segunda derivada: $f''(x) \frac{d}{dx}(a.e^{ax}) = a.(a.e^{ax})$

$$f''(x) = a^2.e^{ax}$$

A segunda derivada deve ser não negativa em todo o intervalo $f(x) \geq 0$. Como $f''(x) = a^2.e^{ax}$ é $\geq 0 \; \forall x \in \mathbb{R}$ e $\forall a \in \mathbb{R}$, a função $f(x) = e^{ax}$ é convexa.

- Função potência: $f(x) = x^a$ é convexa para $a \geq 1$ ou $a \leq 0$ pertencente a $\mathbb{R}_+$.
- Primeira derivada $f'(x) = a.x^{a-1}$
- Segunda derivada $f''(x) = a.(a-1).x^{a-2}$

Para que a função seja convexa, $f''(x) \geq 0$, x é positivo, logo x^{a-2} sempre será positivo.

Para $a \geq 1$: então $a-1 \geq 0$, logo $a(a-1) \geq 0 \Rightarrow f''(x) \geq 0$, é convexa.

Para $a \leq 0$: então $a \leq 0$, $a-1 \leq -1 < 0$, logo $a(a-1) = a(a-1) \geq 0$, (o produto de dois negativos ou zero). $f''(x) \geq 0$, é convexa.

Logo, x^a é convexa para $\forall a \geq 1$ ou $a \leq 0$.

- Função potência: $f(x): x^a$ é côncava para $0 \leq a \leq 1$ pertencente a $\mathbb{R}_+$.

Para que a $f(x): x^a$ seja côncava, a segunda derivada deve ser ≥ 0 no intervalo dado. ($f''(x) \leq 0$).

$f''(x) = a(a-1).x^{a-2}$

Para $0 \leq a \leq 1$;

Se $a = 0$ ou $a = 1$, $f''(x) = 0$, linear (será ambas, convexa e côncava.

Se $0 < a < 1$, então $a > 0$, mas $a-1 < 0$, logo $a(a-1) < 0$, $f''(x) < 0$ será estritamente côncava.

Logo, para $0 \leq a \leq 1$, $f''(x) \leq 0$ é côncava.

a) FUNÇÃO LOGARÍTMICA: $f(x)$: $\log x$ é CÔNCAVA $\forall x \in \mathbb{R}++$.

PRIMEIRA DERIVADA: $f'(x) = \frac{1}{x} = x^{-1}$

SEGUNDA DERIVADA: $f''(x) = -1 \cdot x^{-2} = -\frac{1}{x^2}$

$f''(x) < 0, \forall x \in \mathbb{R}++$

COMO $f''(x)$ é ESTRITAMENTE NEGATIVA, A FUNÇÃO LOGARÍTMICA é ESTRITAMENTE CÔNCAVA.

b) FUNÇÃO AFIM: $a^T x + b$ é AMBAS CONVEXA e CÔNCAVA.

SEGUNDA ORDEM (HESSIANO)

- PRIMEIRA DERIVADA: $\nabla f(x) = a$
- SEGUNDA DERIVADA: $\nabla^2 f(x) = 0$

CONSIDERANDO QUE UMA FUNÇÃO é CONVEXA SE $f''(x) \geq 0$.
CONSIDERANDO TAMBÉM QUE UMA FUNÇÃO é CÔNCAVA SE $f''(x) \leq 0$.

NESTE CASO $\nabla^2 f(x) = 0$ TORNA A FUNÇÃO AFIM $a^t x + b$ CONVEXA E CÔNCAVA.

c) A FUNÇÃO QUADRÁTICA $f(x) = \frac{1}{2} x^T Q x + b^T x + c$ SERÁ CONVEXA SE, SOMENTE SE A MATRIZ Q FOR SEMIDEFINIDA POSITIVA.
UTILIZANDO O MÉTODO HESSIANO:
PRIMEIRA DERIVADA (EM RELAÇÃO A $\vec{x}$): $\nabla f(x) = Qx + b$
SEGUNDA DERIVADA: $\nabla^2 f(x) = Q$ (O HESSIANO é CONSTANTE INDEPENDENTE DE x).
COMO O HESSIANO DESTA FUNÇÃO é A PRÓPRIA MATRIZ Q, A CONDIÇÃO DE CONVEXIDADE é:

$$\nabla^2 f(x) = Q \succeq 0 \ \forall x.$$

d) Provar que a função de perda de mínimos quadrados $f(x) = \|y - Ax\|_2^2$ é convexa.

A função é sempre convexa, porque A^TA é sempre positivo semidefinido. Expandido a função $f(x) = (y - Ax)^T(y - Ax)$, temos:

$$f(x) = y^Ty - y^TAx - x^TA^Ty + x^TA^TAx$$

Já que $y^TAx = x^TA^Ty$ (escalar) então:

$$f(x) = x^T(A^TA)x - 2y^TAx + y^Ty$$

Reescrevendo a função, temos:

$$f(x) = \frac{1}{2}x^TQx + b^Tx + c$$

onde:

$$Q = 2A^TA$$
$$b^T = 2y^TA$$
$$c = y^Ty$$

A^TA sempre será positivo semidefinido para qualquer matriz real A.

$$v^T(A^TA)v = (Av)^T(Av) = \|Av\|_2^2 \geq 0 \ \forall v$$

Assim $Q = 2A^TA$ é também positivo semidefinido (multiplicando por $2 > 0$ preserva o positivo semidefinido).

A função quadrática $\frac{1}{2}x^TQx + b^Tx + c$ é convexa se, somente se, $Q \succeq 0$.

Temos:

$\frac{1}{2}Q = A^TA \succeq 0$, então $Q \succeq 0$, portanto é <u>convexa</u>.

Pelo método de Hessiano

$$\nabla f(x) = 2A^TAx - 2A^Ty$$

$$\nabla^2 f(x) = 2A^TA \succeq 0$$

Constante de Hessiano, positivo semidefinido sempre será <u>convexa</u>.