



PPGEE
Programa de Pós-Graduação em
Engenharia Elétrica - UFAM

UNIVERSIDADE FEDERAL DO AMAZONAS

Programa de Pós-Graduação em Engenharia Elétrica

BENCHMARK COMPUTACIONAL DE PROBLEMAS DE ESCALONAMENTO VIA PROGRAMAÇÃO LINEAR INTEIRA MISTA

Aluno: Wesley Vitorino Teixeira
Matrícula: 2260602

Manaus, AM — Junho 2026

1. Introdução

Este relatório documenta um benchmark computacional aplicado a três formulações de escalonamento, resolvidas via Programação Linear Inteira Mista (MILP) com o solver HiGHS, utilizando a linguagem Julia e a biblioteca de modelagem JuMP.

Os objetivos do benchmark são:

- Avaliar a tratabilidade computacional das formulações Big-M para cada classe de problema;
- Identificar a fronteira de escalabilidade do solver HiGHS em hardware de uso geral;
- Comparar o comportamento do branch-and-bound (nós explorados, gap, tempo) entre os três problemas;
- Fornecer dados empíricos para análise comparativa de complexidade.

2. Ambiente Experimental e Metodologia

2.1 Configuração do Ambiente

Componente	Especificação
Sistema Operacional	Windows 11
Processador	Intel Core i5
Memória RAM	12 GB
Linguagem	Julia 1.12
Biblioteca de Modelagem	JuMP ≥ 1.0
Solver	HiGHS ≥ 1.0
Backend Gráfico	GR (Plots.jl)

2.2 Parâmetros do Solver HiGHS

Parâmetro	Valor	Descrição
time_limit	300s / 600s	Limite de tempo por instância
mip_rel_gap	1×10^{-4}	Gap de otimalidade relativo
primal_feasibility_tolerance	1×10^{-7}	Tolerância de viabilidade primal
mip_abs_gap	1×10^{-6}	Gap absoluto de otimalidade
mip_feasibility_tolerance	1×10^{-6}	Tolerância de integralidade
presolve	on	Pré-solução ativada
threads	2	Threads paralelas (i5 quad-core)

2.3 Formulações MILP

Todos os três problemas foram formulados com a técnica Big-M para a resolução de disjunções de não-sobreposição. As formulações diferem em estrutura e crescimento do número de variáveis:

Problema	Formulação	Variáveis binárias	Variáveis contínuas	Restrições Big-M
Machine Scheduling	$1 r_j \Sigma T_j$	$O(n^2)$	$O(n)$	$O(n^2)$
Job Shop	$Jm Cmax$	$O(n^2 \cdot m)$	$O(n \cdot m)$	$O(n^2 \cdot m)$
Flow Shop (Perm.)	$Fm Cmax$	$O(n^2 \cdot m)$	$O(n \cdot m)$	$O(n^2 \cdot m) + O(n^2 \cdot (m-1))$

A constante Big-M foi fixada em $M = 10^5$ para Machine Scheduling e $M = 10^6$ para Job Shop e Flow Shop, valores suficientemente grandes para não excluir soluções viáveis sem introduzir instabilidade numérica excessiva.

2.3.1 Decisão de Formulação

As formulações MILP adotadas neste trabalho seguem diretamente o referencial do MO-Book (Conejo et al., 2024), que modela o Machine Scheduling e o Job Shop Scheduling por meio de programação disjuntiva — expressando a não-sobreposição entre tarefas como disjunções lógicas explícitas. No MO-Book, essas disjunções são tratadas pelo componente Disjunction da biblioteca Pyomo em Python, que as resolve internamente podendo aplicar tanto a linearização Big-M quanto a formulação de envoltória convexa (*Convex Hull*), conforme configuração do solver. Neste trabalho, a implementação foi realizada em Julia com JuMP, onde não existe componente disjuntivo nativo equivalente. Optou-se, portanto, pela linearização Big-M explícita das disjunções — que é a tradução matemática direta e mais comum dessa classe de restrição na literatura —, preservando a estrutura lógica original do modelo. Para o Flow Shop Scheduling, não há formulação correspondente no MO-Book; o modelo foi construído com base em Pinedo (2016) e Wilson (1989), adicionando restrições de sequência fixa de máquinas e, no caso do *Permutation Flow Shop*, restrições de consistência de ordenação entre máquinas consecutivas. As três formulações compartilham, portanto, a mesma fundamentação teórica do material de referência, diferindo apenas na tecnologia de implementação e no mecanismo de linearização das disjunções.

2.3.2 Aplicação das Regras Heurísticas

As regras heurísticas de sequenciamento — FIFO (*First In, First Out*), EDD (*Earliest Due Date*) e SPT (*Shortest Processing Time*) — foram implementadas e avaliadas exclusivamente para o problema de Machine Scheduling (máquina única). Nesse contexto, as três regras operam de forma direta: os jobs são ordenados segundo um critério simples (tempo de liberação, prazo de entrega ou duração) e executados em sequência na única máquina disponível, gerando schedules válidos imediatamente comparáveis à solução MILP. Os gráficos de Gantt correspondentes — FIFO, EDD, SPT e MILP — foram gerados e salvos para cada instância selecionada, permitindo comparação visual direta entre as abordagens heurística e ótima.

Para o Job Shop Scheduling e o Flow Shop Scheduling, as regras FIFO, EDD e SPT não foram aplicadas. Nesses problemas, cada job possui múltiplas operações distribuídas em máquinas distintas, o que torna inválida a aplicação direta dessas regras de ordenação. Nesses ambientes multi-máquina, as heurísticas equivalentes são denominadas regras de despacho (*dispatching rules*), que operam de forma dinâmica: a cada instante em que uma máquina fica disponível, uma regra decide qual operação pendente será processada a seguir. Sua implementação requer uma lógica de simulação evento-a-evento, que está fora do escopo deste benchmark, cujo foco é a avaliação de formulações MILP. Os gráficos de Gantt gerados para o Job Shop e o Flow Shop representam, portanto, exclusivamente a solução obtida pelo solver HiGHS, visualizando o schedule ótimo — ou o melhor schedule viável encontrado dentro do limite de tempo — para cada instância.

Os gráficos Gantt encontram-se no capítulo 9 em apêndice.

3. Machine Scheduling ($1|r_j|\Sigma T_j$)

3.1 Descrição do Problema

O problema $1|r_j|\Sigma T_j$ consiste em escalonar n tarefas em uma única máquina, minimizando a soma dos atrasos individuais (*past due*). Cada tarefa j possui tempo de liberação r_j , duração p_j e prazo de entrega d_j . A formulação Big-M emprega variáveis binárias $z(i,j)$ para cada par de tarefas, gerando $O(n^2)$ binárias e $O(n^2)$ restrições de disjunção.

3.2 Instâncias

Foram testadas 31 instâncias com $n \in \{5, 7, 9, 11, 13, 15, 17, 19, 21, 24\}$ jobs, cada grupo com 3 sementes distintas (s01, s02, s03), além da instância inst_book extraída da referência bibliográfica base. Limite de tempo: 300 segundos por instância.

3.3 Resultados

Instância	n	Variáveis	Status	Objetivo	Gap (%)	Tempo (s)	Nós B&B
inst_book	7	42	OPTIMAL	16	0.00	0.466	56
inst_n05_s01	5	25	OPTIMAL	7	0.00	0.017	1
inst_n05_s02	5	25	OPTIMAL	15	0.00	0.057	1
inst_n05_s03	5	25	OPTIMAL	3	0.00	0.011	1
inst_n07_s01	7	42	OPTIMAL	38	0.00	0.189	42
inst_n07_s02	7	42	OPTIMAL	30	0.00	0.424	378
inst_n07_s03	7	42	OPTIMAL	26	0.00	0.113	33

inst_n09_s01	9	63	OPTIMAL	26	0.00	0.298	74
inst_n09_s02	9	63	OPTIMAL	56	0.00	1.268	2,030
inst_n09_s03	9	63	OPTIMAL	32	0.00	3.411	6,770
inst_n11_s01	11	88	OPTIMAL	16	0.00	1.943	297
inst_n11_s02	11	88	OPTIMAL	62	0.00	11.881	18,764
inst_n11_s03	11	88	OPTIMAL	116	0.96	248.582	364,732
inst_n13_s01	13	117	OPTIMAL	71	0.90	101.535	111,557
inst_n13_s02	13	117	OPTIMAL	98	0.95	59.625	56,038
inst_n13_s03	13	117	OPTIMAL	71	0.00	3.628	4,890
inst_n15_s01	15	150	TIME LIM	138	7429.00	300.025	280,014
inst_n15_s02	15	150	TIME LIM	123	5520.00	300.025	350,162
inst_n15_s03	15	150	OPTIMAL	62	0.98	33.025	21,701
inst_n17_s01	17	187	TIME LIM	167	6977.00	300.027	212,469
inst_n17_s02	17	187	TIME LIM	155	9310.00	300.025	97,852
inst_n17_s03	17	187	TIME LIM	108	7238.00	300.026	265,144
inst_n19_s01	19	228	TIME LIM	261	9430.00	300.048	30,724
inst_n19_s02	19	228	TIME LIM	120	9843.00	300.057	36,213
inst_n19_s03	19	228	TIME LIM	229	9477.00	300.050	27,992
inst_n21_s01	21	273	TIME LIM	204	9277.00	300.055	22,920
inst_n21_s02	21	273	TIME LIM	202	9950.00	300.064	28,475
inst_n21_s03	21	273	TIME LIM	188	9477.00	300.048	12,929
inst_n24_s01	24	348	TIME LIM	133	10000.00	300.044	25,691
inst_n24_s02	24	348	TIME LIM	247	9921.00	300.052	17,282
inst_n24_s03	24	348	TIME LIM	294	9744.00	300.040	17,660

Legenda: Gap reportado em % do valor objetivo.

3.4 Análise

Fronteira de escalabilidade: o solver encontrou solução ótima comprovada para todas as instâncias com $n \leq 13$ jobs (com exceção de inst_n15_s03, que convergiu em 33s). A partir de $n = 15$, o crescimento quadrático das variáveis binárias — de $n(n-1)/2$ pares — torna o espaço de busca exponencialmente mais amplo.

Comportamento do gap: nas instâncias com TIME_LIMIT, o gap cresce dramaticamente com n : de 55–74% para $n=15$ até 97–100% para $n=24$. Isso evidencia que a relaxação linear das restrições Big-M fornece bounds duais muito fracos para instâncias maiores, característica conhecida da formulação Big-M aplicada a problemas de scheduling.

Explosão de nós: inst_n11_s03 demandou 364.732 nós para ser resolvida otimamente em 248s, contrastando com inst_n13_s03 que precisou de apenas 4.890 nós em 3,6s — evidenciando a alta sensibilidade da dificuldade em relação às características específicas de cada instância (estrutura dos tempos de processamento e janelas temporais).

Tempo médio (ótimas): 27,44 segundos, com variância elevada (0,011s a 248,58s), refletindo a heterogeneidade das instâncias.

4. Job Shop Scheduling (Jm||Cmax)

4.1 Descrição do Problema

No Job Shop Scheduling Jm||Cmax cada job j possui uma sequência de m operações, onde a k -ésima operação deve ser processada em uma máquina específica $\mu(j,k)$ por um tempo fixo. As restrições são de dois tipos: precedência interna (operações de um mesmo job devem respeitar a sequência) e não-sobreposição (cada máquina processa no máximo uma operação por vez). O objetivo é minimizar o makespan C_{max} .

4.2 Resultados

Instância	n	m	Status	Cmax	Ótimo ref.	Gap vs Ót. (%)	Gap MILP (%)	Tempo (s)
abz5	10	10	TIME LIM	1238	1234	0.32	15.67	600.98
abz6	10	10	OPTIMAL	943	943	0.00	0.00	172.37
ft06	6	6	OPTIMAL	55	55	0.00	0.00	0.42
ft10	10	10	TIME LIM	1007	930	8.28	25.93	600.09
ft20	20	5	TIME LIM	1257	1165	7.90	61.05	600.13
la01	10	5	OPTIMAL	666	666	0.00	0.00	74.88
la02	10	5	TIME LIM	655	655	0.00	21.36	674.07
la03	10	5	TIME LIM	901	597	50.92	54.73	15598.00
la04	10	5	OPTIMAL	590	590	0.00	0.00	132.95
orb01	10	10	TIME LIM	1222	1059	15.39	35.19	1366.51

Legenda: Gap vs Ót. = desvio percentual em relação ao optimum conhecido da literatura. > 10% = ruim,, 0–10% = ótimo comprovado.

4.3 Análise

Instâncias resolvidas até o ótimo: ft06 (6×6, 0,42s), abz6 (10×10, 172s), la01 (10×5, 74,9s) e la04 (10×5, 132,9s). Todos com gap vs. literatura de 0%, confirmando a corretude da formulação.

Caso la03: resultado crítico — solver retornou Cmax=901 contra otimalidade conhecida de 597 (gap de 50,9%). A instância atingiu TIME_LIMIT com apenas 1 nó explorado e tempo de 15.598s, indicando que o solver ficou travado na resolução da relaxação linear raiz, sem iniciar o branch-and-bound efetivamente. Este comportamento é atribuído à

qualidade do dual bound fornecido pela relaxação Big-M, que pode ser muito fraco para instâncias com estrutura específica.

Instância orb01: consumiu 1.366s (mais que o limite de 600s configurado, pois o limite foi atingido após um round de nós em andamento), com gap de 35,2% e desvio de 15,4% em relação ao ótimo (1059). Demonstra a dificuldade das instâncias 10×10 para formulações Big-M.

Comparação ft06 × ft10 × ft20: ft06 (6×6) resolvido em 0,42s; ft10 (10×10) atingiu TIME_LIMIT com gap de 25,9%; ft20 (20×5) também em TIME_LIMIT com gap de 61,1%. O crescimento do número de máquinas impacta mais que o de jobs, pois multiplica o número de pares em conflito por m.

5. Flow Shop Scheduling (Fm||Cmax)

5.1 Descrição do Problema

O Flow Shop Fm||Cmax é uma versão restrita do Job Shop onde todos os jobs percorrem as máquinas na mesma sequência fixa ($m_1 \rightarrow m_2 \rightarrow \dots \rightarrow m_m$). A formulação MILP empregada é do tipo Permutation Flow Shop, que adiciona restrições de consistência entre máquinas consecutivas ($y[(i,j),m+1] = y[(i,j),m]$), reduzindo o espaço de busca ao impor que a ordem relativa entre pares de jobs seja a mesma em todas as máquinas.

A estrutura do modelo resulta em $O(n^2 \cdot m)$ variáveis binárias e $O(n^2 \cdot m) + O(n^2 \cdot (m-1))$ restrições, tornando instâncias de grande porte computacionalmente intratáveis com formulação Big-M pura.

5.2 Resultados

Instância	n	m	Status	Cmax	Gap (%)	Bound	Tempo (s)	Nós B&B
problem_10m_20j	20	10	TIME LIM	321	52.57	152.30	601.465	16,502
problem_3m_20j	20	3	TIME LIM	218	66.54	72.90	600.112	59,183
problem_5m_10j	10	5	OPTIMAL	129	0.00	129.00	62.599	18,879
problem_5m_20j	20	5	TIME LIM	273	58.97	112.00	600.199	55,115
problem_5m_30j	30	5	TIME LIM	354	72.41	97.70	600.268	7,008
problem_8m_10j	10	8	OPTIMAL	187	0.00	187.00	82.680	22,243

5.3 Análise

Instâncias resolvidas: problem_5m_10j (10 jobs × 5 máquinas, Cmax=129, 62,6s) e problem_8m_10j (10 jobs × 8 máquinas, Cmax=187, 82,7s). Ambas com 10 jobs —

confirmando que a fronteira viável está em torno de $n=10$ para esta formulação no hardware testado.

Efeito do número de máquinas: `problem_8m_10j` (441 variáveis, 1.115 restrições) foi mais rápida que `problem_5m_10j` (276 variáveis, 680 restrições) — aparente paradoxo explicado pela estrutura da instância específica: `problem_8m_10j` possui tempos de processamento que permitem ao presolver eliminar mais variáveis e restrições redundantes.

Escalabilidade com $n=20$ e $n=30$: Todas as instâncias com 20 ou 30 jobs atingiram `TIME_LIMIT` com gaps entre 52,6% e 72,4%. O `problem_5m_30j`, com 2.326 variáveis e 6.240 restrições, explorou apenas 7.008 nós em 600s — evidenciando que a maior parte do tempo foi consumida na resolução das relaxações lineares ao longo da árvore.

6. Análise Comparativa

6.1 Resumo Consolidado

Problema	Instâncias	OPTIMAL	TIME_LIMIT	Tempo médio (ótimas)	Fronteira viável
Machine Scheduling	31	17 (54,8%)	14 (45,2%)	27,44s	≤ 13 jobs
Job Shop	10	4 (40,0%)	6 (60,0%)	95,16s	6×6 , 10×5
Flow Shop	6	2 (33,3%)	4 (66,7%)	72,64s	≤ 10 jobs

6.2 Complexidade e Escalabilidade

Os três problemas compartilham a formulação Big-M para disjunções, mas diferem estruturalmente:

- Machine Scheduling (single machine): $O(n^2)$ binárias. Fronteira $\sim n=13$. Dificuldade determinada pela combinação de janelas temporais e relações de precedência implícitas.
- Job Shop Scheduling: $O(n^2 \cdot m)$ binárias, mas apenas entre pares que realmente conflitam (mesma máquina). A esparsidade dos conflitos torna instâncias 10×5 mais tratáveis que 10×10 .
- Flow Shop Scheduling: $O(n^2 \cdot m)$ binárias + restrições de permutação. O tightening pela permutação reduz o espaço, mas o volume de restrições ainda cresce rapidamente com n e m .

Em termos de taxa de sucesso (OPTIMAL): Machine Scheduling 54,8%, Job Shop 40,0%, Flow Shop 33,3%. A ordenação reflete tanto a complexidade intrínseca quanto o tamanho das instâncias testadas.

6.3 Qualidade do Dual Bound (Big-M)

Um padrão consistente observado nos três problemas é a fragilidade do dual bound produzido pela relaxação linear das formulações Big-M. Nas instâncias com TIME LIMIT:

- Machine Scheduling $n=24$: gaps de 97–100%, bound ≈ 0 — a relaxação LP é quase trivialmente satisfeita.
- Job Shop la03: bound de 407,9 contra solução de 901 (gap 54,7%) e apenas 1 nó explorado.
- Flow Shop $5m \times 30j$: bound de 97,7 contra 354 (gap 72,4%).

Este é um fenômeno bem documentado na literatura: formulações Big-M para scheduling produzem relaxações LP fracas, pois a constante M introduz folga excessiva nas restrições. Formulações alternativas — como time-indexed, positional variables ou disjunctive graph — tendem a produzir bounds mais fortes ao custo de maior número de variáveis.

6.4 Comportamento do Branch-and-Bound

O número de nós explorados varia de 0 (ft06 — resolvido na raiz LP) a 364.732 (inst_n11_s03). Instâncias com bound forte relativo à solução ótima tendem a exigir mais nós (busca mais profunda), enquanto instâncias com bound muito fraco atingem TIME_LIMIT com relativamente poucos nós (o solver passa mais tempo resolvendo relaxações LP do que ramificando).

Caso particular: la02 (10×5, TIME_LIMIT) apresentou Cmax=655 = otimalidade conhecida (gap vs. ótimo=0%), porém sem prova de otimalidade dentro do limite de 674s. Isso indica que o solver encontrou a solução ótima mas não conseguiu certifi  -la via dual bound.

7. Conclusões

O benchmark demonstrou que formulações MILP Big-M com o solver HiGHS são viáveis para instâncias de pequeno porte dos três problemas de scheduling testados, em hardware de uso geral (Intel Core i5, 12 GB RAM, Windows 11):

- Machine Scheduling: resolução ótima garantida até $n=13$ jobs em tempo compatível com uso interativo (< 5 minutos).
- Job Shop Scheduling: instâncias clássicas de referência (ft06, abz6, la01, la04) resolvidas até o ótimo. Instâncias 10×10 representam o limite prático da formulação Big-M.
- Flow Shop Scheduling: instâncias com até 10 jobs e 8 máquinas resolvidas. O limite de escalabilidade está em torno de $n=10-12$ para o hardware testado.

A principal limitação identificada é a qualidade do dual bound nas formulações Big-M, que produz gaps muito elevados para instâncias maiores, tornando impossível certificar a otimalidade dentro do limite de tempo. Para trabalhos futuros, recomenda-se:

- Investigar formulações alternativas com bounds mais fortes (time-indexed, positional).
- Aplicar heurísticas de geração de cortes (cutting planes) para fortalecer a relaxação LP raiz.
- Explorar decomposição (Lagrangiana, Benders) para instâncias de grande porte.

O ambiente de benchmark desenvolvido em Julia/JuMP é modular, extensível e totalmente reproduzível, constituindo base sólida para as etapas subsequentes de análise e comparação com abordagens heurísticas.

8. Referências

CONEJO, A. J. et al. *Hands-On Mathematical Optimization with Python* (MO-Book). Disponível em: <https://mobook.github.io/MO-book>. Acesso em: jun. 2026.

PINEDO, M. L. *Scheduling: Theory, Algorithms, and Systems*. 5. ed. New York: Springer, 2016.

WILSON, J. M. Alternative formulations of a flow-shop scheduling problem. *Journal of the Operational Research Society*, v. 40, n. 4, p. 395–399, 1989

APPLEGATE, D.; COOK, W. A computational study of the job-shop scheduling problem. *ORSA Journal on Computing*, v. 3, n. 2, p. 149–156, 1991.

FISHER, H.; THOMPSON, G. L. Probabilistic learning combinations of local job-shop scheduling rules. *Factory Scheduling Conference*, Carnegie Mellon University, 1963.

HIGHS DEVELOPMENT TEAM. HiGHS: High Performance Software for Linear Optimization. Disponível em: <https://highs.dev>. Acesso em: jun. 2026.

LAWLER, E. L. et al. Sequencing and scheduling: algorithms and complexity. *Handbooks in Operations Research and Management Science*, v. 4, p. 445–522, 1993.

LUBIN, M.; DUNNING, I. Computing in operations research using Julia. *INFORMS Journal on Computing*, v. 27, n. 2, p. 238–248, 2015.

MO-BOOK. Machine Scheduling. Disponível em: <https://mobook.github.io/MO-book/notebooks/03/05-machine-scheduling.html>. Acesso em: jun. 2026.

PINEDO, M. L. *Scheduling: Theory, Algorithms, and Systems*. 5. ed. New York: Springer, 2016.

TAILLARD, E. Benchmarks for basic scheduling problems. *European Journal of Operational Research*, v. 64, n. 2, p. 278–285, 1993.


9. Apêndice

9.1 Gráficos Grantt


9.1.2 Machine Scheduling

Os gráficos de Gantt correspondentes — FIFO, EDD, SPT e MILP — foram gerados para cada instância selecionada .

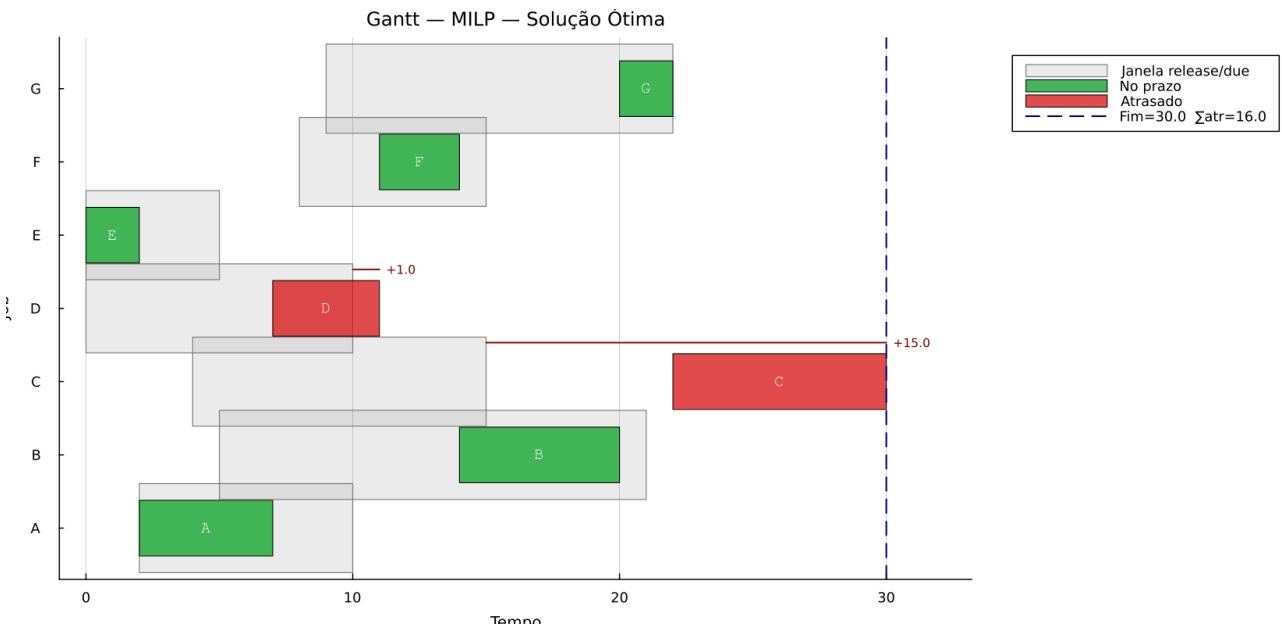
inst_book_gantt_edd



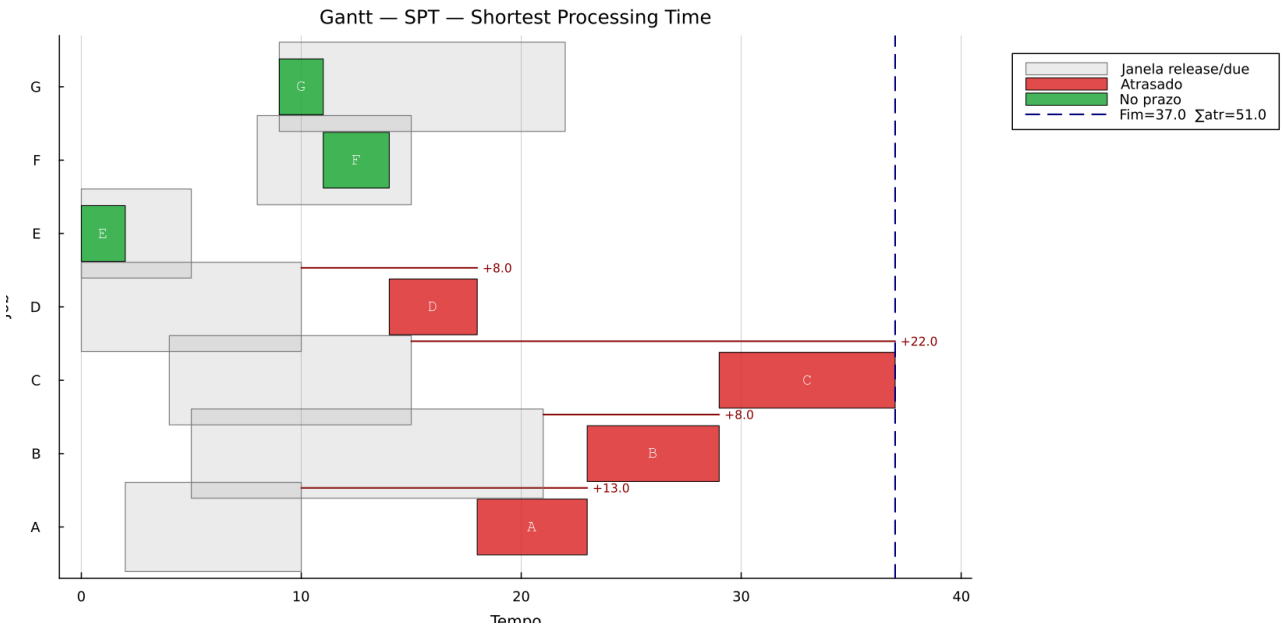
inst_book_gantt_fifo




inst_book_gantt_milp




inst_book_gantt_spt




inst_n05_s01_gantt_edd



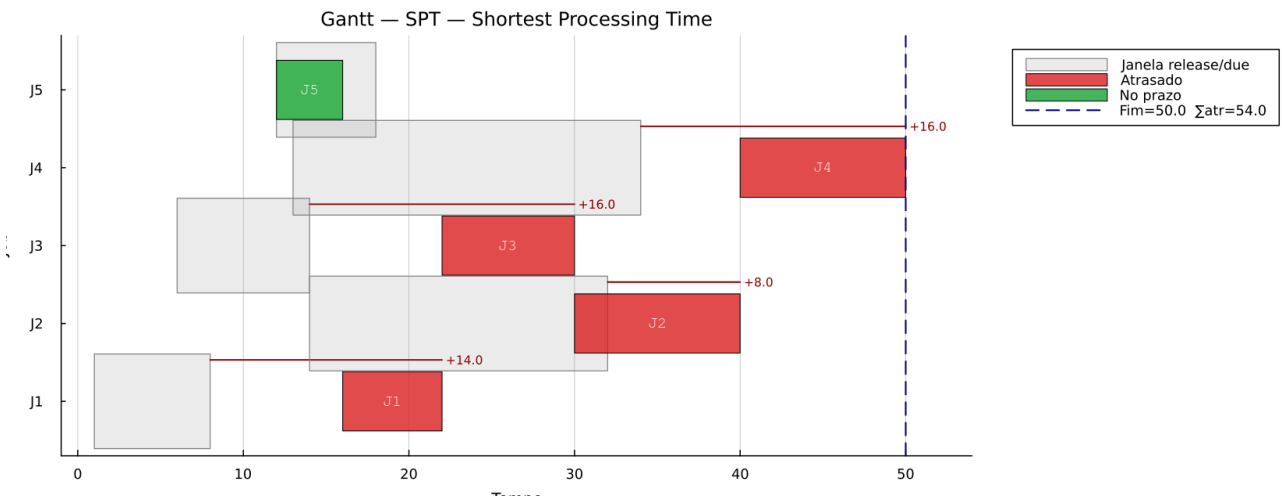
inst_n05_s01_gantt_fifo




inst_n05_s01_gantt_milp




inst_n05_s01_gantt_spt




inst_n05_s02_gantt_edd



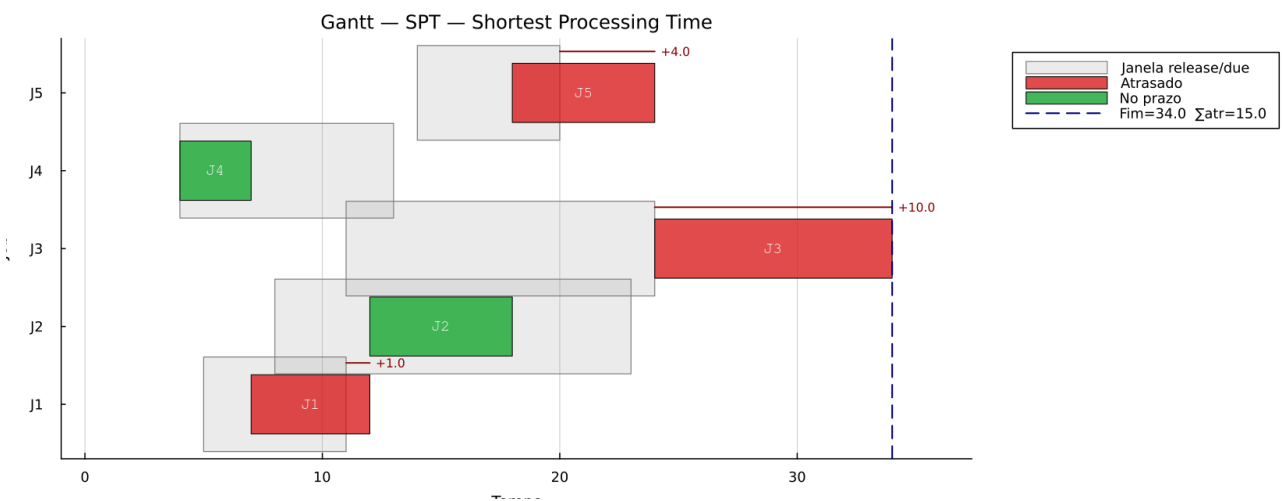
inst_n05_s02_gantt_fifo




inst_n05_s02_gantt_milp




inst_n05_s02_gantt_spt




inst_n05_s03_gantt_edd



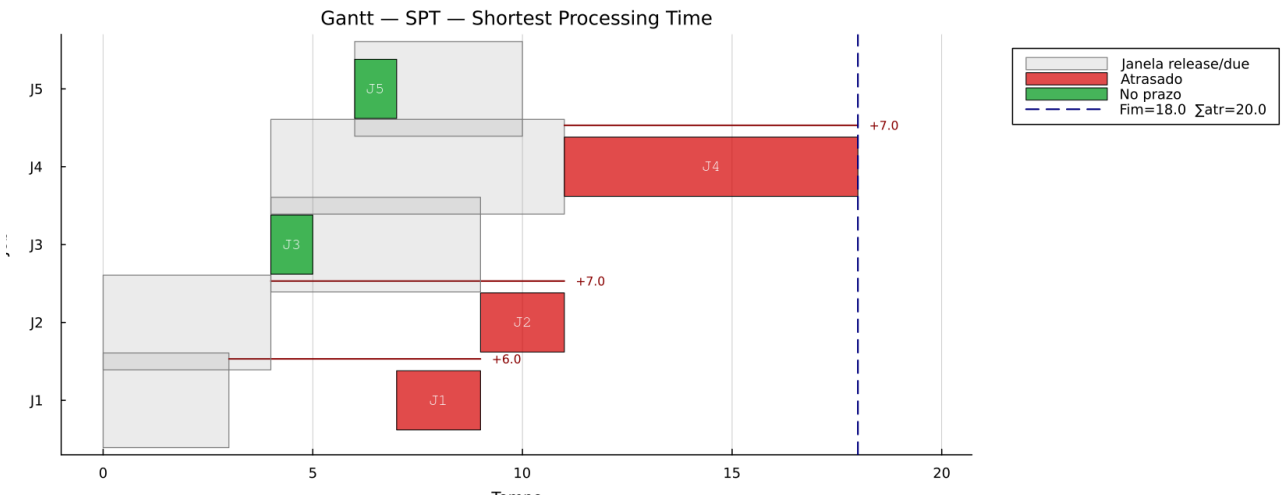
inst_n05_s03_gantt_fifo




inst_n05_s03_gantt_milp



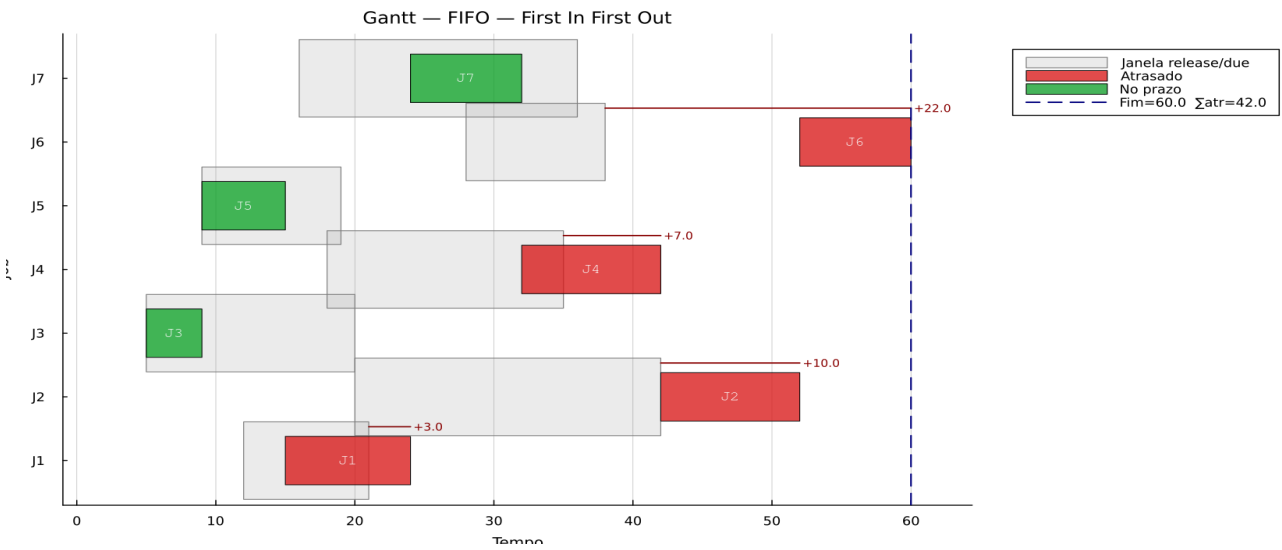
inst_n05_s03_gantt_spt



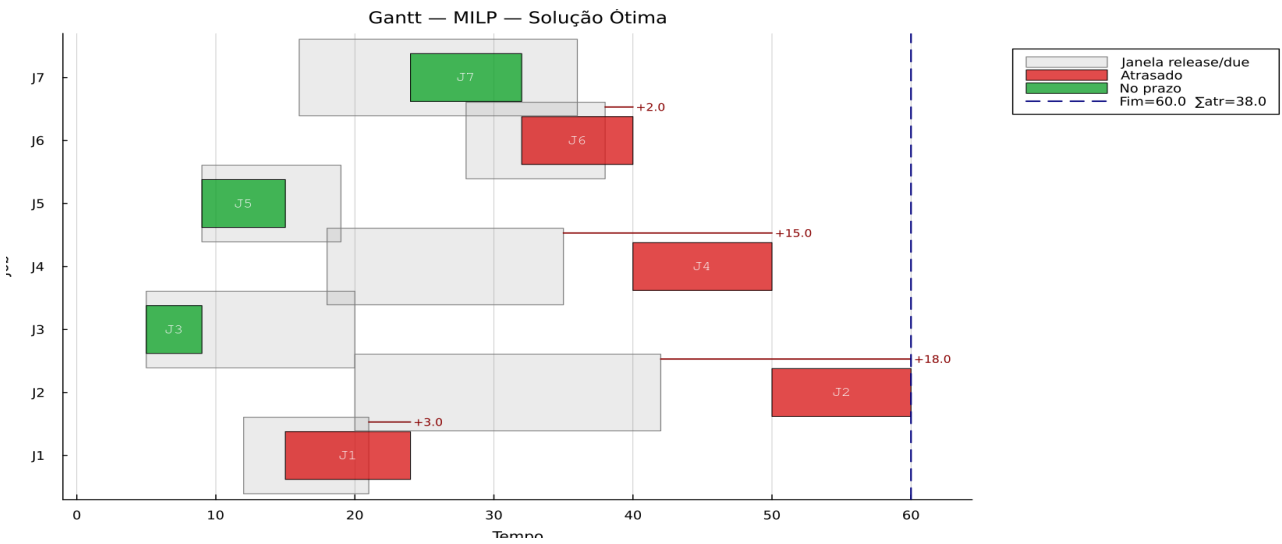
inst_n07_s01_gantt_edd



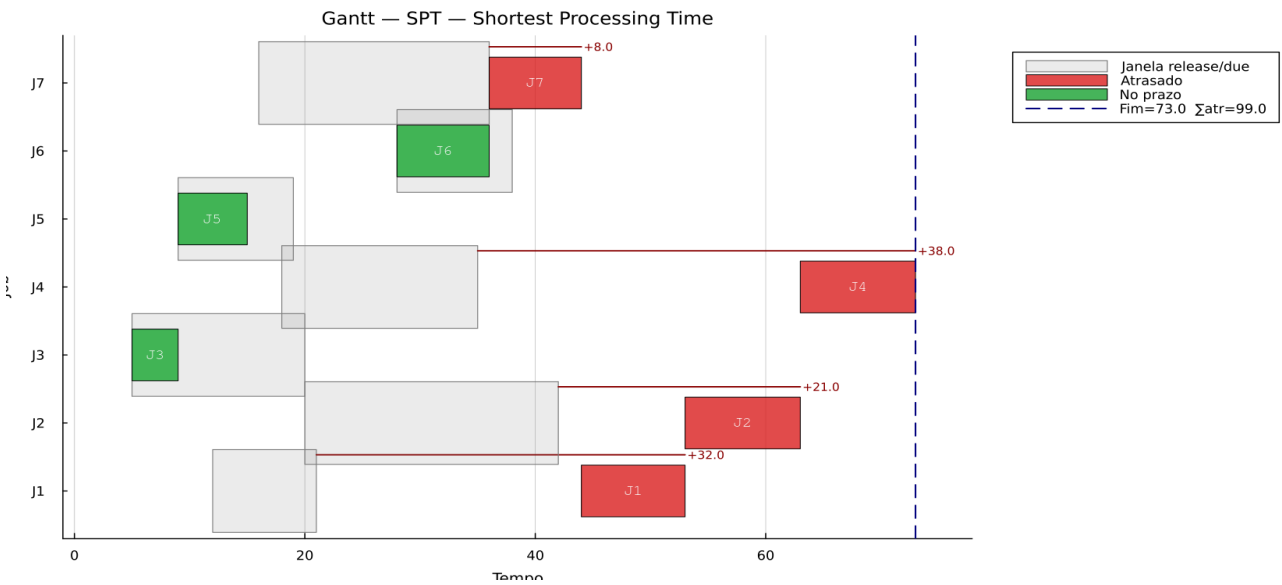
inst_n07_s01_gantt_fifo



inst_n07_s01_gantt_milp




inst_n07_s01_gantt_spt




9.1.3 Flow Shop

Para o Flow Shop Scheduling, as regras FIFO, EDD e SPT não foram aplicadas. Nesses problemas, cada job possui múltiplas operações distribuídas em máquinas distintas, o que torna inválida a aplicação direta dessas regras de ordenação.


problem_3m_20j_gantt_milp




problem_5m_10j_gantt_milp




problem_5m_20j_gantt_milp



problem_5m_30j_gantt_milp




problem_10m_20j_gantt_milp




9.1.4 Job Shop

Como no Flow Shop, as regras FIFO, EDD e SPT não foram aplicadas ao Job Shop Scheduling . Nesses problemas, cada job possui múltiplas operações distribuídas em máquinas distintas, o que torna inválida a aplicação direta dessas regras de ordenação.


ft06_gantt_milp




abz5_gantt_milp



ft20_gantt_milp



abz6_gantt_milp



ft10_gantt_milp

